Métodos Numéricos y Optimización
Lecture 21: Optimización

Martín Palazzo

Universidad de San Andrés
Ingeniería en Inteligencia Artificial

palazzom@udesa.edu.ar

June 10, 2024

Overview

1. Optimización: Programación Lineal
2. Programación Lineal: Algoritmo del Simplex y variables Slack
3. Implementación computacional del Simplex
4. Análisis de Sensibilidad
5. Optimización con Primal y Dual
6. Programación Lineal: transporte

Optimización: Programación Lineal

Optimización: Programación Lineal

Motivación

Dado una **función objetivo**

$$f(x) : \mathbb{R}^n \to \mathbb{R}$$

continua y diferenciable donde su dominio

$$x \in \mathbb{R}^n$$

queremos encontrar el valor de las **variables de decisión $\mathbf{x}^*$** (coordenadas) del dominio que asegura que en alguno de los casos

$$\min_x f(x) \text{ o } \max_x f(x)$$

donde la **variable de decisión $\mathbf{x}^*$** que determina el óptimo se la conoce como *Argumento Máximo* o *Argumento mínimo*

Optimización: Programación Lineal

Restricciones y conjunto factible

El dominio de búsqueda puede estar acotado por

$$\begin{aligned} \text{restricciones lineales de igualdad } Ax &= b \\ \text{restricciones de desigualdad } Ax &\leq b \\ \text{restricciones de variables enteras } x_i &\in 0, 1 \end{aligned}$$

el conjunto de soluciones que satisfacen las restricciones se lo denomina **conjunto factible**

Optimización: Programación Lineal

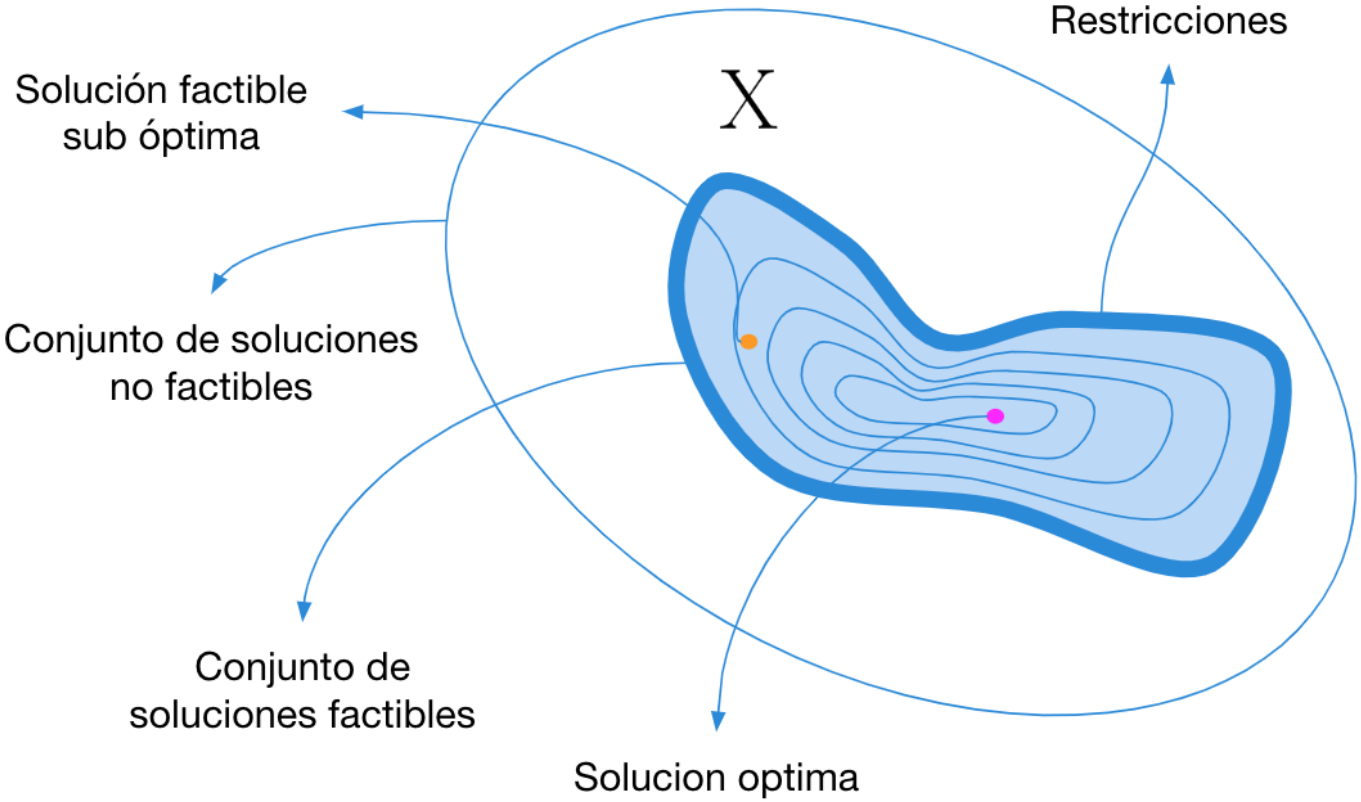

Figure: Conjunto factible

Optimización: Programación Lineal

En base al tipo de función objetivo y restricciones

- Programación Lineal
- Programación cuadrática
- Programación No lineal

En base al dominio de búsqueda y la función objetivo

- Programación Convexa
- Programación No convexa

En base a sus variables de decisión

- Optimización de variables continuas
- Optimización de variables entera (Programación entera)

Optimización: Programación Lineal

Programación Lineal

la función

$$f(x) : \mathbb{R}^n \to \mathbb{R}$$

es lineal, continua y diferenciable

$$f(x) = c_1 x_1 + \cdots + c_n x_n$$

$$x \in \mathbb{R}^n$$

y las restricciones del dominio

$$\begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &\leq b_1 \\ \cdots + \cdots + \ldots &\leq \ldots \\ a_{mn}x_1 + \cdots + a_{mn}x_n &\leq b_m \end{aligned}$$

Optimización: Programación Lineal

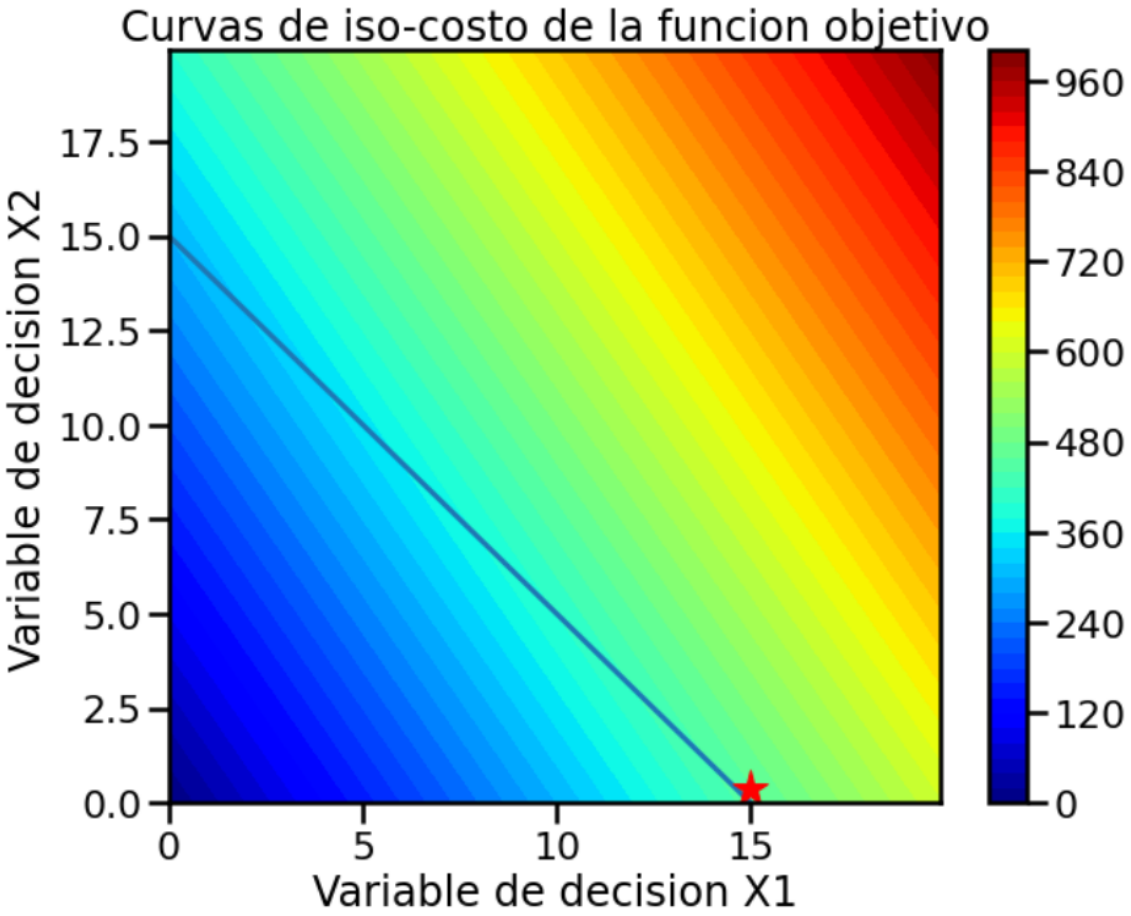

Figure: Solución **Argumento maximo** en $x^* = [15, 0]$ con máximo de $f(x^*) = 450$ de la función objetivo lineal $f(x) = 30x_1 + 20x_2$ y su restricción $x_1 + x_2 \leq 15$

Programación Lineal: Algoritmo del Simplex y variables Slack

Variables Slack

Supongamos el siguiente problema de Programación Lineal

$$c_1x_1 + c_2x_2 = \mathbf{z}$$
$$a_{11}x_1 + a_{12}x_2 \leq b_1$$
$$a_{21}x_1 + a_{22}x_2 \leq b_2$$

Variables Slack

$$c_1x_1 + c_2x_2 + 0x_3 + 0x_4 = \mathbf{z}$$
$$a_{11}x_1 + a_{12}x_2 + x_3 + 0x_4 = b_1$$
$$a_{21}x_1 + a_{22}x_2 + 0x_3 + x_4 = b_2$$

El problema de la slide anterior puede re-escribirse transformando las inecuaciones en ecuaciones y agregando una variable *Slack* por cada inecuación del problema original. Es decir incorporando las nuevas variables

$$x_3, x_4$$

representan la distancia ortogonal de una solución factible del problema a las restricciones.

Algoritmo del Simplex

Cambio de base iterativo

Moviendose de vértice en vértice el algoritmo del Simplex propone una solución *básica* en cada iteración. Es decir que existe una base vectorial solución en cada paso. De la slide anterior, si el simplex comienza en el origien, la solución base es

- $x_3 = b_1, x_4 = b_2$
- $x_0 = 0, x_1 = 0$

es decir que al inicio la solución radica en la variables *activas* x_3, x_4. En cada iteración una de las variables inactivas entra a la base y sale una de la actual base.

Algoritmo del Simplex

Función Objetivo	$Z_0 = 0$	$Z_1 = \#\# > Z_0$	$Z_2 = \#\# > Z_1$	$Z_3 = \#\# > Z_2$
Solución básica	$Xi = \# > 0$ $Xj = \# > 0$	$Xi = \# > 0$ $Xk = \# > 0$	$Xe = \# > 0$ $Xk = \# > 0$	$Xe = \# > 0$ $Xh = \# > 0$
Iteración	T = 0	T = 1	T = 2	T = 3

Figure: Iterativamente el Simplex "activa" y "desactiva" variables haciendolas entrar y salir de la solución básica siendo equivalente a moverse únicamente por los vértices del poligono de soluciones posibles.

Algoritmo del Simplex

Algorithm Simplex: encontrar x^* optimo en programación lineal

Require: $c^T \cdot x \wedge A \cdot x = b$

Solución básica inicial $x_3 = b_1, x_4 = b_2, x_1 = 0, x_2 = 0$

Costo de oportunidad variable de entrada a la base Δ_i

Costo de moverse a la restricción y vértice mas cercano γ_j

while $\Delta_i < 0$ **do**

Ingresar a la base la variable no-básica i tal que $\mathbf{max}_i |\Delta_i|$

Egresar de la base la variable básica j tal que $\mathbf{min}_j |\gamma_i|$

end while

return x_i^*

Algoritmo del Simplex

Suponer el ejercicio

$$\max_x \qquad Z = 1000x_1 + 1200x_2$$

$$\begin{aligned} 10x_1 + 5x_2 &\leq 200 \\ 2_x1 + 3x_2 &\leq 60 \\ x_1 &\leq 34 \\ x_2 &\leq 14 \\ x_1, x_2 &\geq 0 \end{aligned}$$

Algoritmo del Simplex

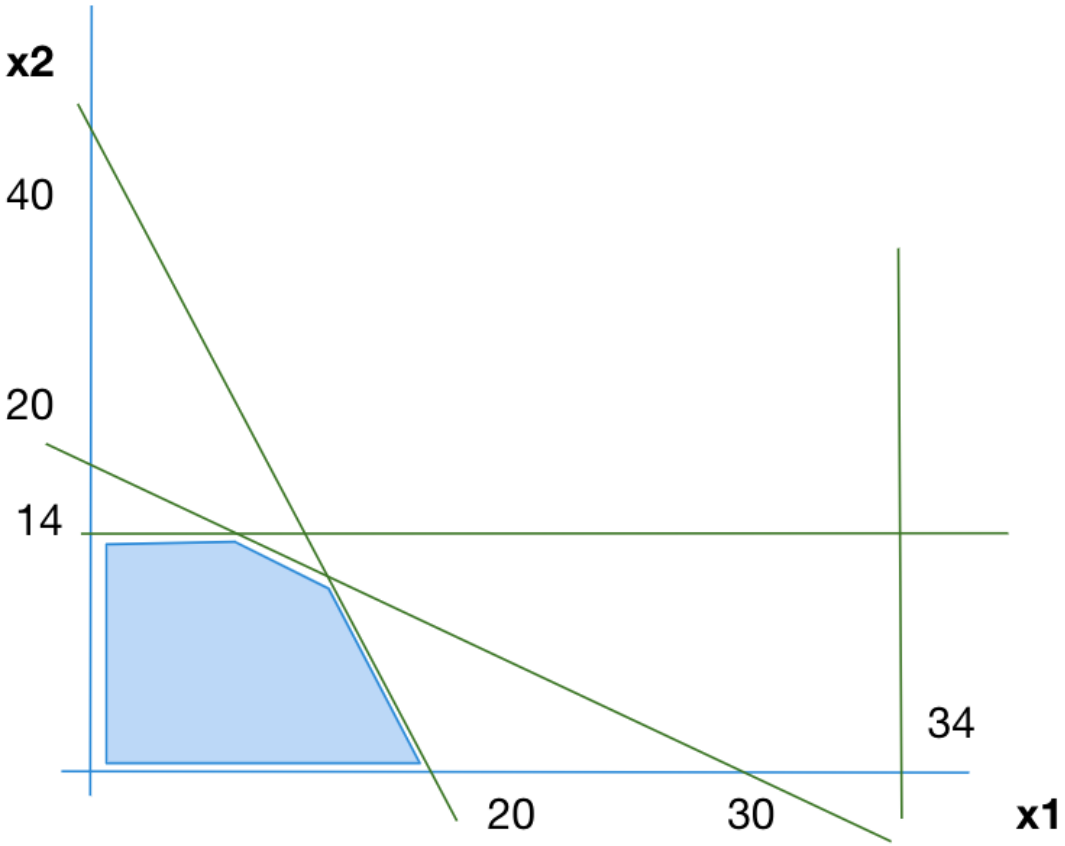

Algoritmo del Simplex

Adaptando el problema a variables *slack*

$$\begin{gathered}
\boldsymbol{max} Z = 1000\boldsymbol{x_1} + 1200\boldsymbol{x_2} + 0 \cdot \boldsymbol{x_3} + 0 \cdot \boldsymbol{x_4} + 0 \cdot \boldsymbol{x_5} + 0 \cdot \boldsymbol{x_6} \\
10x_1 + 5x_2 + x_3 + 0x_4 + 0x_5 + 0x_6 = 200 \\
2x_1 + 3x_2 + 0x_3 + x_4 + 0_x5 + 0x = 60 \\
x_1 + 0x_3 + 0x_4 + x_5 + 0x_6 = 34 \\
x_2 + 0x_3 + 0x_4 + 0x_5 + x_6 = 14 \\
x_1, x_2, x_3, x_4, x_5, x_6 \geq 0
\end{gathered}$$

Algoritmo del Simplex

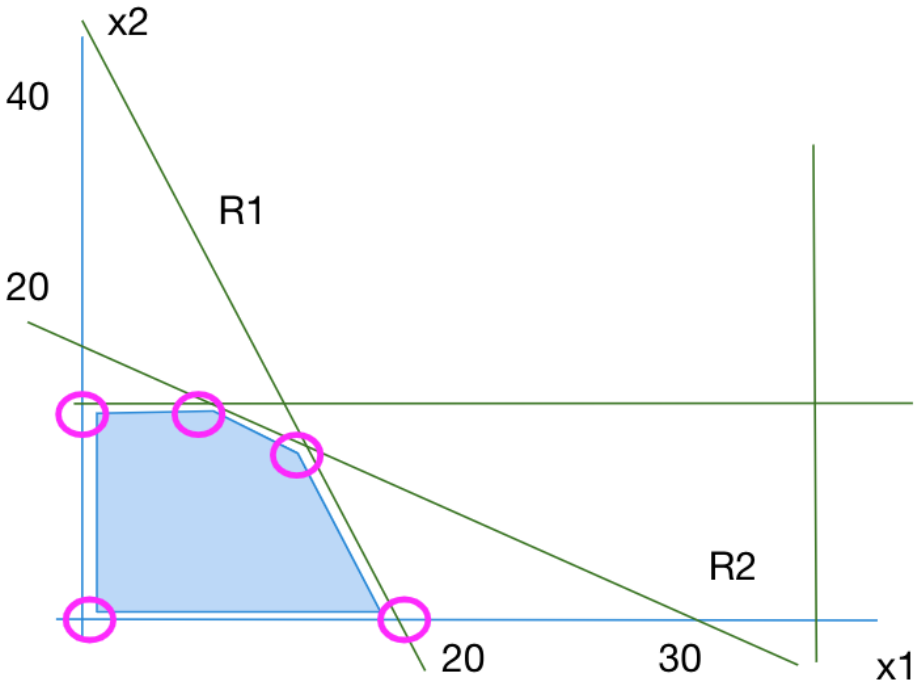

Figure: Soluciones que toma el simplex en cada iteración.

En el origen (primera iteración)
$x_1 = 0, x_2 = 0, x_3 = b_3, x_4 = b_4, x_5 = b_6, x_6 = b_7$, es decir que las últimas 4 son variables básicas. Que variable entra y que variable sale en la segunda iteración?

Tabla del Simplex

Del ejercicio

$$\boldsymbol{max} Z = 1000\boldsymbol{x_1} + 1200\boldsymbol{x_2} + 0 \cdot \boldsymbol{x_3} + 0 \cdot \boldsymbol{x_4} + 0 \cdot \boldsymbol{x_5} + 0 \cdot \boldsymbol{x_6}$$
$$10x_1 + 5x_2 + x_3 + 0x_4 + 0x_5 + 0x_6 = 200$$
$$2x_1 + 3x_2 + 0x_3 + x_4 + 0_x5 + 0x = 60$$
$$x_1 + 0x_3 + 0x_4 + x_5 + 0x_6 = 34$$
$$x_2 + 0x_3 + 0x_4 + 0x_5 + x_6 = 14$$
$$x_1, x_2, x_3, x_4, x_5, x_6 \geq 0$$

En la cáda iteración el Simplex construye la siguiente tabla

x_1	x_2	s_1	s_2	s_3	s_4	z	b
10	5	1	0	0	0	0	200
2	3	0	0	1	0	0	60
1	0	0	0	0	1	0	34
0	1	0	0	0	0	1	14
-1000	-1200	0	0	0	0	1	0

La matriz de identidad indica la solución básica

Implementación computacional del Simplex

Algoritmo del Simplex

```python
# definimos si es un problema de minimizacion o maximizacion
prob1 = LpProblem("Toy example 1", LpMaximize)

# definimos las variables de decision
x1 = LpVariable('x1', lowBound=0, cat='Continuous')
x2 = LpVariable('x2', lowBound=0, cat='Continuous')

# primero agregamos la funcion objetivo
prob1 += 300 * x1 + 200 * x2, "Funcion objetivo"

prob1 += 2*x1 + 1*x2 <= 8, "restriccion 1"
prob1 += 1 * x1 + 2 * x2 <= 8, "restriccion 2"

# Resolver el problema con el solver de PULP
prob1.solve()
```

$$
\begin{aligned}
300x_1 + 200x_2 &= z \\
2x_1 + x_2 &\leq 8 \\
x_1 + 2x_2 &\leq 8
\end{aligned}
$$

Figure: La librería PULP (https://coin-or.github.io/pulp/) tiene un wrapper del algoritmo del simplex.

Análisis de Sensibilidad

Análisis de Sensibilidad

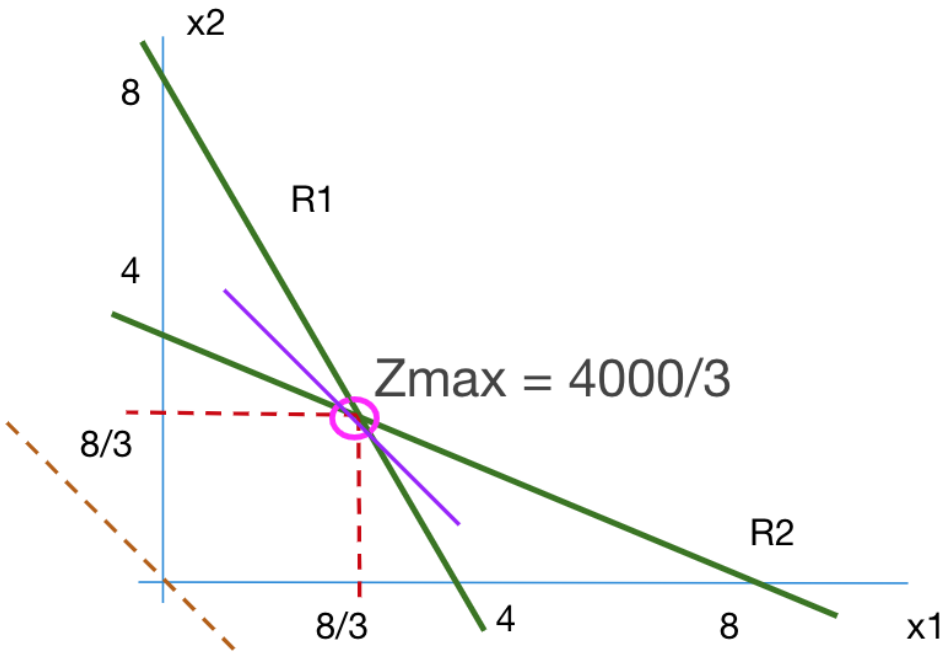

$$\begin{aligned} 300x_1 + 200x_2 &= z \\ 2x_1 + x_2 &\leq 8 \\ x_1 + 2x_2 &\leq 8 \end{aligned}$$

Figure: Problema inicial

Análisis de Sensibilidad

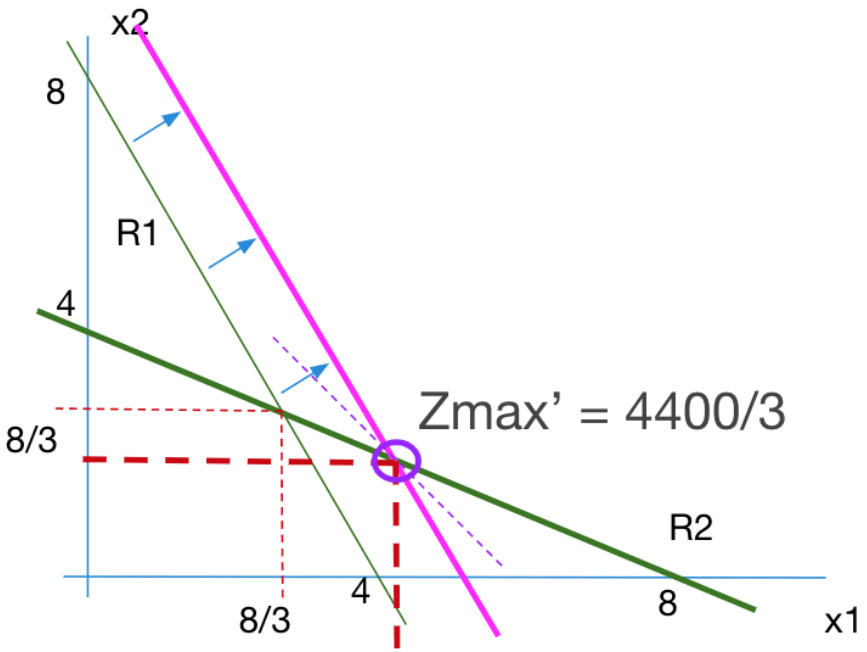

$$
\begin{aligned}
300x_1 + 200x_2 &= z \\
2x_1 + x_2 &\leq 9 \\
x_1 + 2x_2 &\leq 8
\end{aligned}
$$

Figure: Variamos un parámetro

Análisis de Sensibilidad

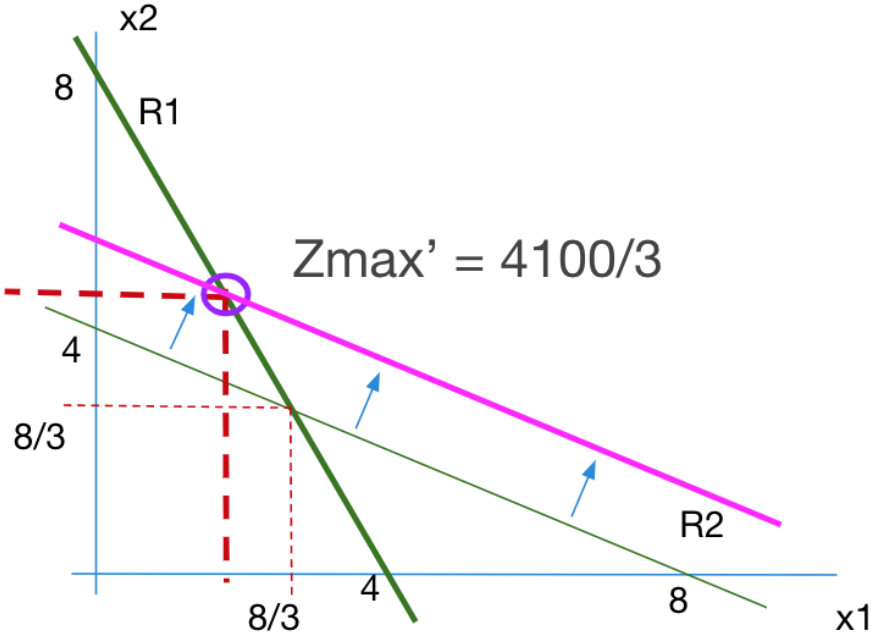

$$\begin{aligned} 300x_1 + 200x_2 &= z \\ 2x_1 + x_2 &\leq 8 \\ x_1 + 2x_2 &\leq 9 \end{aligned}$$

Figure: Variamos un parámetro

Análisis de Sensibilidad

```python
# creo una matriz vacia para ir guardando las variables de decision en cada prueba parametrica
x_param_analysis_b1 = np.zeros((20,2))

# creo un vector vacio para ir guardando la funcion objetivo en cada prueba parametrica
sol_param_b1 = np.zeros((20))

# contador para ir contando cuantas iteraciones hice
counter = 0
for i in range(1,21):

  # definimos si es un problema de minimizacion o maximizacion
  prob_sens_b1 = LpProblem("Sensitivity analysis", LpMaximize)

  # definimos las variables de decision
  x1 = LpVariable('x1', lowBound=0, cat='Continuous')
  x2 = LpVariable('x2', lowBound=0, cat='Continuous')

  # primero agregamos la funcion objetivo
  prob_sens_b1 += 300 * x1 + 200 * x2, "Funcion objetivo"

  # definimos restricciones
  prob_sens_b1 += 2*x1 + 1*x2 <= i, "restriccion 1"
  prob_sens_b1 += 1 * x1 + 2 * x2 <= 8, "restriccion 2"

  # Resolver el problema con el solver de PULP
  prob_sens_b1.solve()

  # valor de la funcion objetivo
  sol_param_b1[counter] = value(prob_sens_b1.objective)

  # obtenemos el valor de la variable de decision X1 en el punto optimo
  x_param_analysis_b1[counter,0] = prob_sens_b1.variables()[0].varValue
  x_param_analysis_b1[counter,1] = prob_sens_b1.variables()[1].varValue

  counter += 1
  print("solve iteration " + str(i))
```

$$
\begin{aligned}
300x_1 + 200x_2 \quad &= z \\
2x_1 + 1x_2 \quad &\leq b_1 = 1, 2, \ldots, 10 \\
1x_1 + 2x_2 \quad &\leq b_2 = 1, 2, \ldots, 10
\end{aligned}
$$

Figure: Computacionalmente podemos pensar este ensayo

Análisis de Sensibilidad

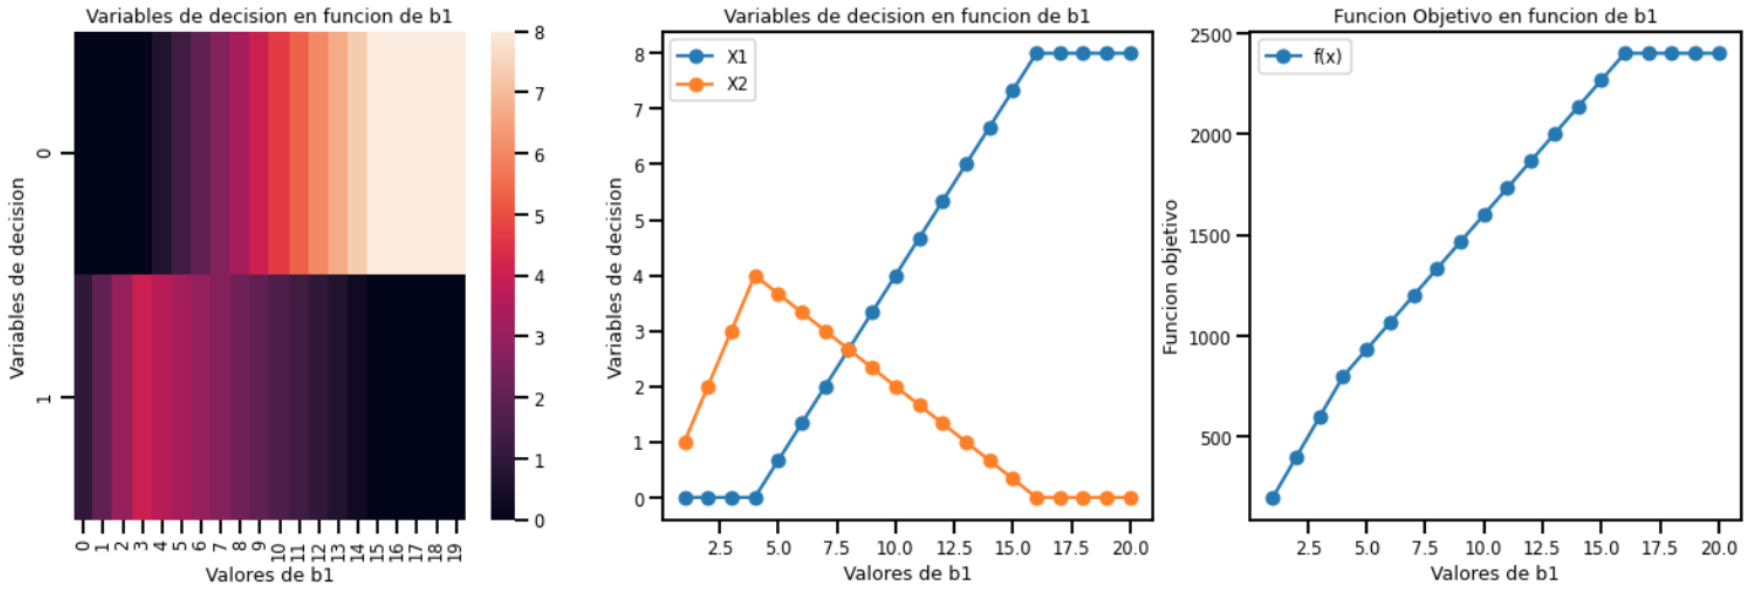

Figure: Visualización de como varia la función objetivo en el optimo para cada variación del parámetro

Análisis de Sensibilidad

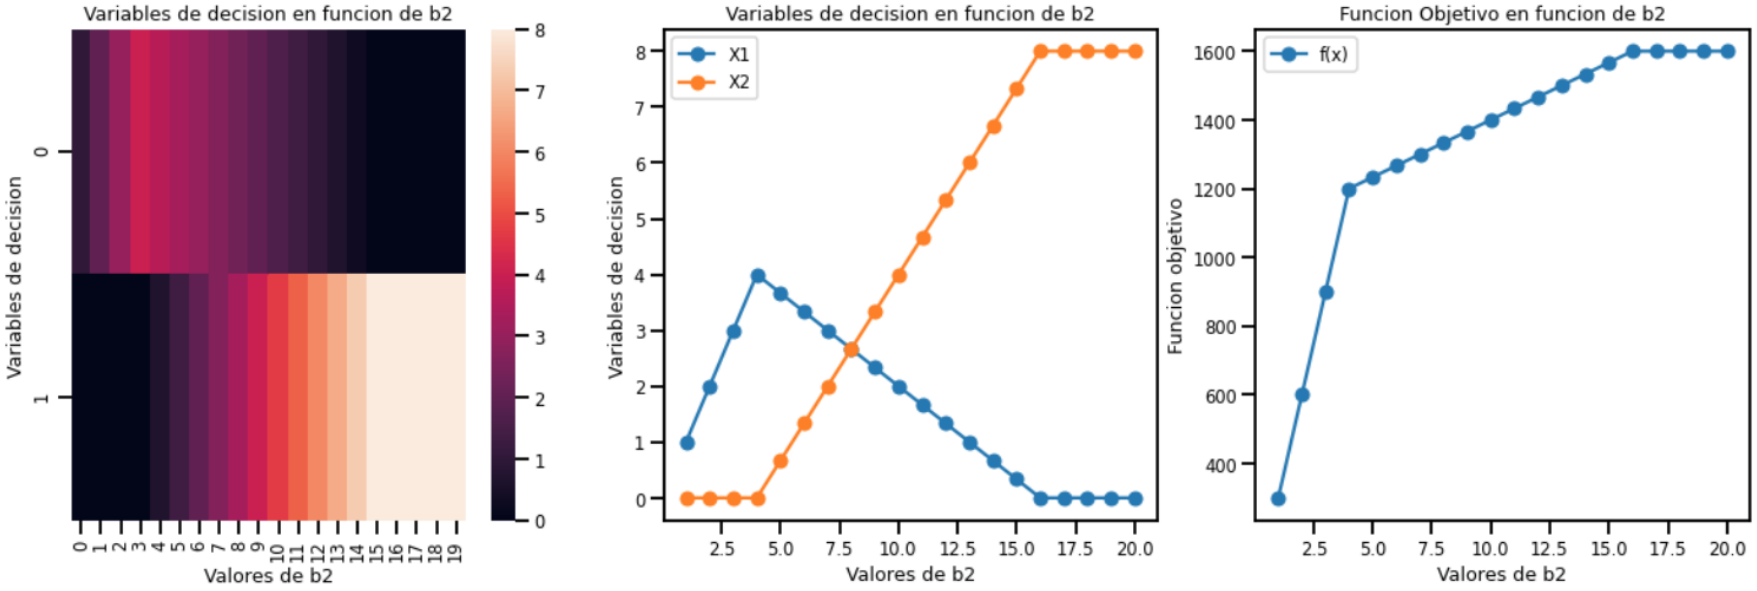

Figure: Visualización de como varia la función objetivo en el optimo para cada variación del parámetro

Análisis de Sensibilidad

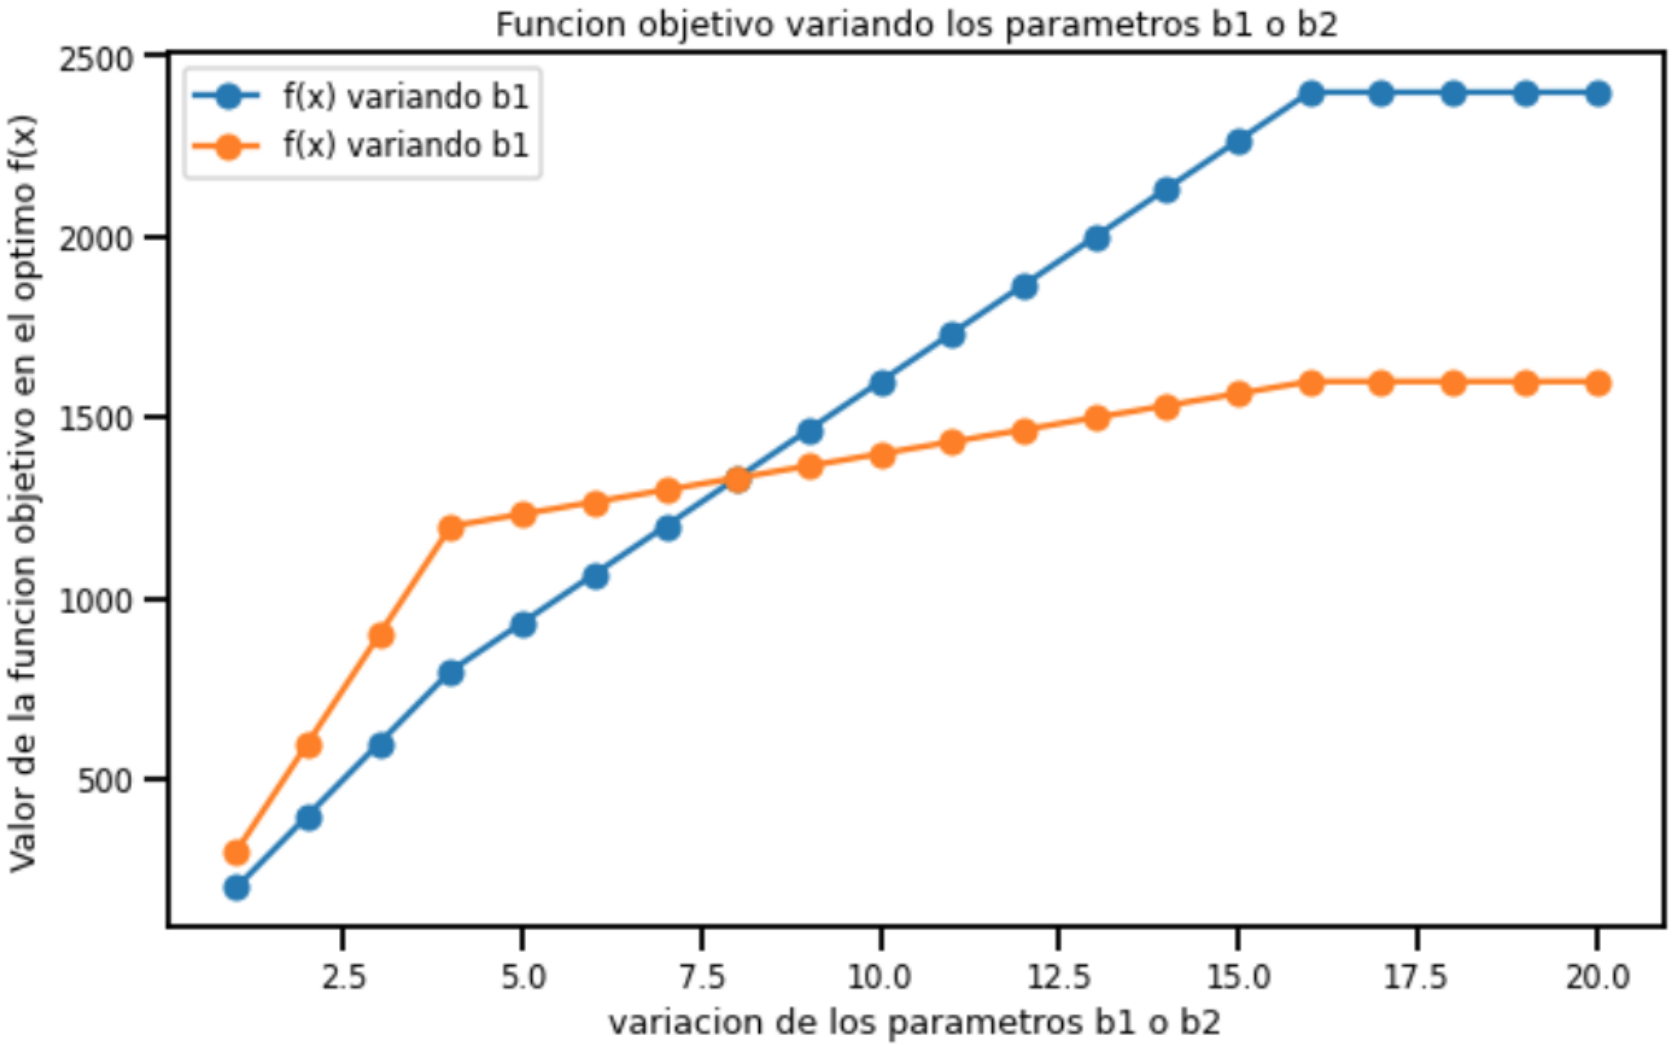

Figure: Visualización de como varia la función objetivo en el optimo para cada variación del parámetro

Optimización con Primal y Dual

Optimización Primal y Dual

El problema original es llamado modelo Primal. En el ejemplo: problema de optimización (maximizacion) de programación lineal

$$\begin{aligned} \mathbf{c}^T\mathbf{x} &= \mathbf{z} \\ A\mathbf{x} &\leq \mathbf{b} \\ \mathbf{x} &\geq 0 \end{aligned}$$

El problema dual es un problema de programación lineal definido de manera directa a partir del modelo original primal. Ambos problemas están relacionados de tal forma que la solución óptima del primal produce la solución óptima del dual

Optimización Primal y Dual

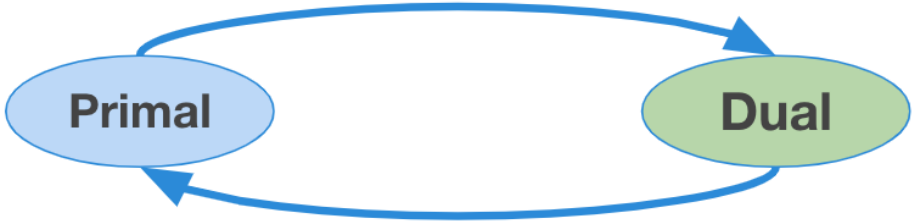

Figure: De un problema primal podemos ir a un problema dual.

Problema	Objetivo		Restricciones	
Primal	Maximizacion	Minimizacion	$<$	$>$
Dual	Minimizacion	Maximizacion	$>$	$<$

Optimización Primal y Dual

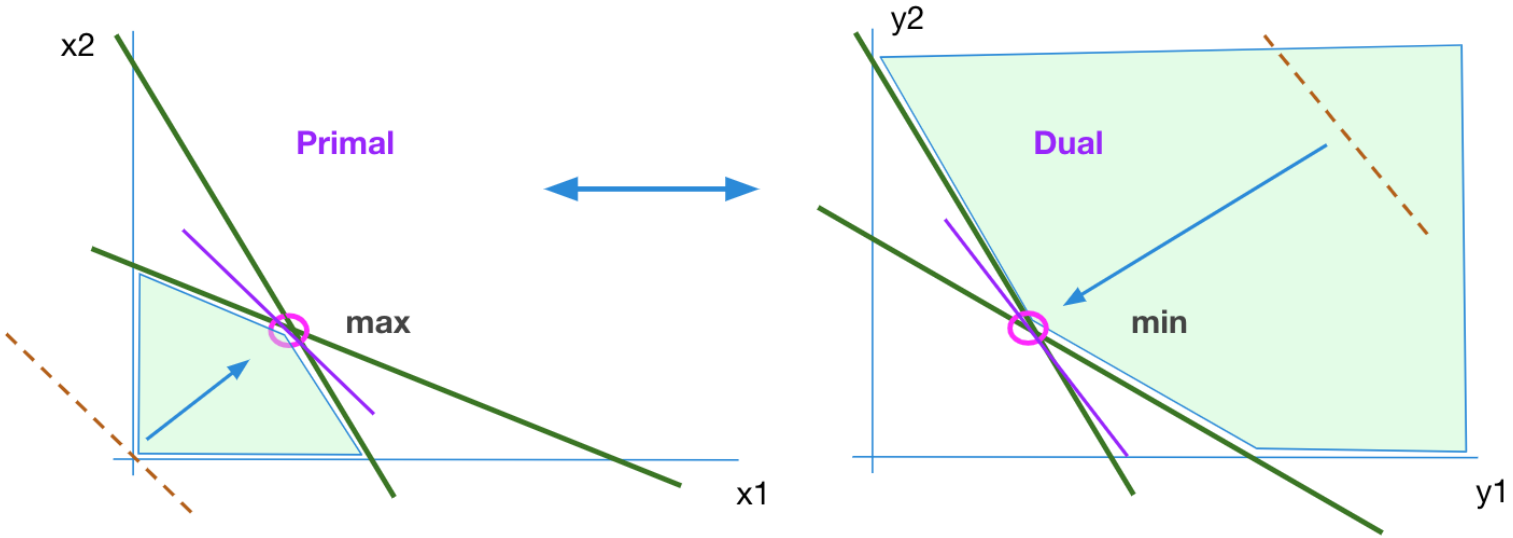

Figure: El problema de maximizacion (izq) tiene asociado un problema de minimización (der). Ambos problemas pueden traducirse de uno a otro mediante el planteo primal-dual. La solución del funcional Z en ambos casos será la misma aunque los valores que tomen las variables de decisión en cada caso serán propios de cada problema.

Optimización Primal y Dual

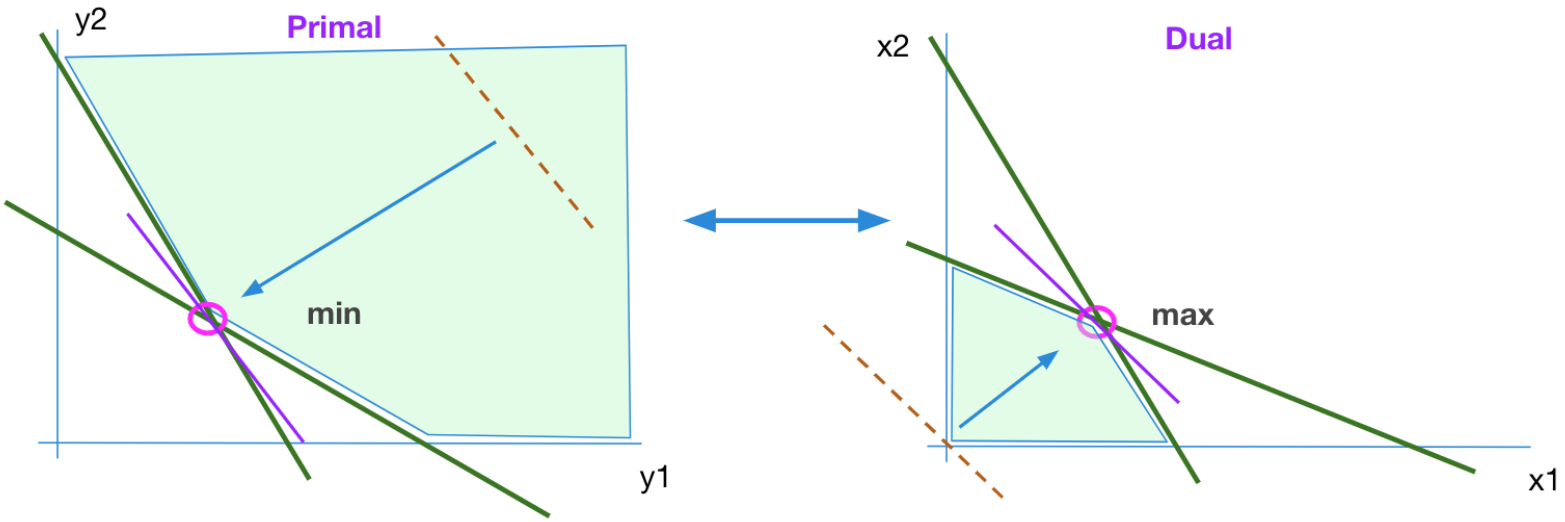

Figure: El problema primal de minimizacion (izq) tiene asociado un problema dual de maximizacion (der). Ambos problemas pueden traducirse de uno a otro mediante el planteo primal-dual. La solución del funcional Z en ambos casos será la misma aunque los valores que tomen las variables de decisión en cada caso serán propios de cada problema.

Optimización Primal y Dual

$$\begin{aligned} \max_x \mathbf{c}^T\mathbf{x} &= z \\ \mathbf{A}\mathbf{x} &\leq \mathbf{b} \\ \mathbf{x} &\geq 0 \end{aligned} \qquad \begin{aligned} \min_b \mathbf{b}^T\mathbf{y} &= w \\ \mathbf{A}^T\mathbf{y} &\geq \mathbf{c} \\ \mathbf{y} &\geq 0 \end{aligned}$$

El problema primal de la izquierda tiene asociado un problema dual. La solución de la función objetivo en ambos casos es la misma.

$$\mathbf{c}^T\mathbf{x} = z \leq \mathbf{b}^T\mathbf{y} = w$$

Esta relación es válida para cualquier par de soluciones primales y duales factibles. Es importante observar que la relación no especifica cuál problema es primal y cuál es dual. El problema primal suele ser el problema que se presenta originalmente. En este caso solo importa el sentido de la optimización (maximización o minimización).

Optimización Primal y Dual

Por ejemplo dado el siguiente problema primal

$$
\begin{gathered}
5x_1 + 4x_2 = z \\
\text{s.t.} \\
6x_1 + 4x_2 \leq 24 \\
x_1 + 2x_2 \leq 6 \\
-x_1 + x_2 \leq 1 \\
0x_1 + x_2 \leq 2
\end{gathered}
$$

su dual asociado es

$$
\begin{gathered}
24y_1 + 6y_2 + y_3 + 2y_4 = w \\
\text{s.t.} \\
6y_1 + y_2 - y_3 + 0y_4 \geq 5 \\
4y_1 + 2y_2 + y_3 + y_4 \geq 4
\end{gathered}
$$

Optimización Primal y Dual

Primal: Maximizacion

$$\begin{aligned} 5x_1 + 4x_2 &= z \\ \text{s.t.} & \\ 6x_1 + 4x_2 &\leq 24 \\ x_1 + 2x_2 &\leq 6 \\ -x_1 + x_2 &\leq 1 \\ 0x_1 + x_2 &\leq 2 \end{aligned}$$

Dual: Minimizacion

$$\begin{aligned} 24y_1 + 6y_2 + y_3 + 2y_4 &= w \\ \text{s.t.} & \\ 6y_1 + y_2 - y_3 + 0y_4 &\geq 5 \\ 4y_1 + 2y_2 + y_3 + y_4 &\geq 4 \end{aligned}$$

Solución factible óptima Primal

$$(x_1 = 3, x_2 = 1.5) \rightarrow z = 21$$

Solución factible óptima Dual

$$(y_1 = 0.75, y_2 = 0.5, y_3 = y_4 =) \rightarrow w = 21$$

Figure: La solución de la función objetivo en el óptimo será la misma.

Esto quiere decir que si tenemos un caso de optimización podemos decidir si queremos resolver por primal o dual y luego inferir la solución del problema original.

Optimización Primal y Dual

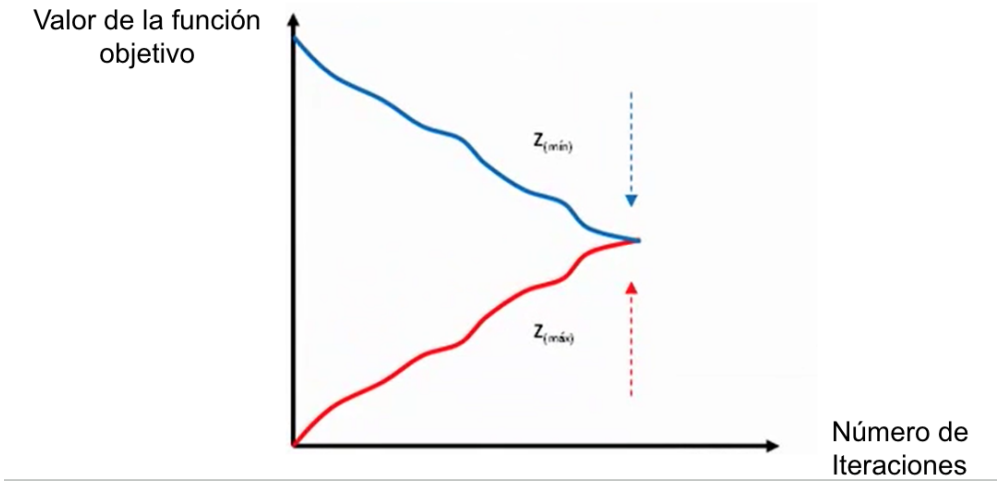

Figure: En problemas de optimización muy grandes, calculando ambos primal y dual podemos aproximar el resultado de convergencia.

$$z = \sum_{j=1}^{n} c_j x_j \leq \sum_{i=1}^{m} b_i y_i = w$$

Únicamente en la solución óptima el valor del funcional del primal sera igual al funcional del dual y viceversa de manera que z = w. Para el resto de las soluciones el valor del funcional en maximización $<$ minimización.

Optimización Primal y Dual

Figure: El hecho de que un problema de optimización presente un equivalente dual permite evaluar cuál de los dos problemas es más conveniente de resolver. Si un problema primal tiene más restricciones que variables en su dual tendrá más variables que restricciones y viceversa. Dependiendo de estos contextos en algunos casos convendrá resolver el problema en el dual. En otros casos el dual será más complejo y el primal será conveniente.

Optimización Primal y Dual

Ejercicio

Una compañía de seguros está en proceso de introducir dos nuevas líneas de productos: seguro de riesgo especial e hipotecas. La ganancia esperada es de 50000 pesos por el seguro de riesgo especial y de 2 pesos por unidad de hipoteca. La administración desea establecer las cuotas de venta de las nuevas líneas para maximizar la ganancia total esperada. Los requerimientos de trabajo son los siguientes:

	Horas de trabajo por unidad		Horas de trabajo disponibles
Departamento	**Riesgo especial**	**Hipoteca**	
Suscripciones	3	2	2 400
Administración	0	1	800
Reclamaciones	2	0	1 200

Modelar el caso como uno de optimización en su forma primal y dual definiendo variables de decisión, función objetivo y restricciones. Graficar el caso de maximización.

Programación Lineal: transporte

Programación Lineal: transporte

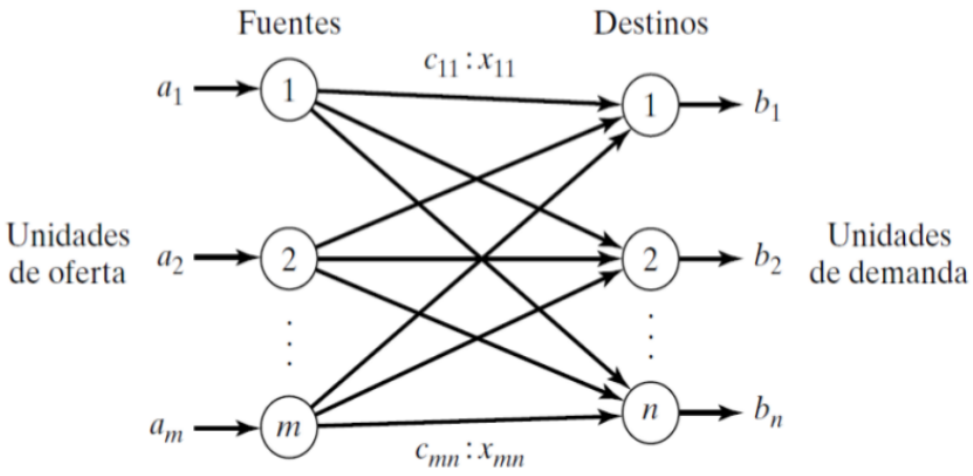

Figure: Funcion a optimizar

Podemos representar el problema con un grafo direccionado donde los nodos de de origen representan las plantas productoras mientras que los nodos destino representan los centros de distribución. Por otro lado, los arcos representan las rutas posibles entre nodo y nodo caracterizados con un "peso" o "costo" por cada unidad de transporte. Finalmente, la variable a determinar será la matriz X que indica cuánto transportar destino a destino.

Programación Lineal: Transporte

Supuestos

En este modelo lo que deseamos distribuir es un solo producto

- La cantidad total de unidades a distribuir que ofrecen los orígenes es igual a las cantidades totales de unidades que requieren los destinos.
- Es posible transportar entre todos los orígenes y todos los destinos pero debe incurrir en un costo unitario de transportar una unidad entre el origen i y el destino j.
- El objetivo es el transporte de todos los orígenes a todos los destinos minimizando el costo
- Hay que decidir cuánto enviar por cada canal (matrix X)

Programacion lineal: transporte

Figure: Mapa de transporte

Supongamos que tenemos el producto Quilmes Cristal que se produce y embotella en la planta Quilmes, Córdoba y Tucuman.
Por otro lado tenemos centros de distribución que abastecen a los clientes de distintas zonas y son Neuquen, Mendoza, Mar del Plata y Santa Fe.
Cada transporte del destino "i" al "j" tendra un costo asociado Cij.
Queremos transportar el 100 % del producto minimizando el costo total.
Por ende lo que debemos calcular es la cantidad Xij a transportar desde cada destino "i" a cada destino "j".

Programacion lineal: transporte

Destino Origen	Neuquen	Mendoza	MDQ	Sta. Fe	Oferta
Quilmes	X11	X12	X13	X14	**75**
Cordoba	X21	X22	X23	X24	**125**
Tucuman	X31	X32	X33	X34	**100**
Demanda	**80**	**65**	**70**	**85**	**300**

Programacion lineal: transporte

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{23} & x_{34} \end{bmatrix}$$

Cuanto vale la matriz X que minimiza el costo del problema de transporte?
La matriz de costo

$$C = \begin{bmatrix} c_{11} & c_{12} & c_{13} & c_{14} \\ c_{21} & c_{22} & c_{23} & c_{24} \\ c_{31} & c_{32} & c_{33} & c_{34} \end{bmatrix}$$

Programacion lineal: transporte

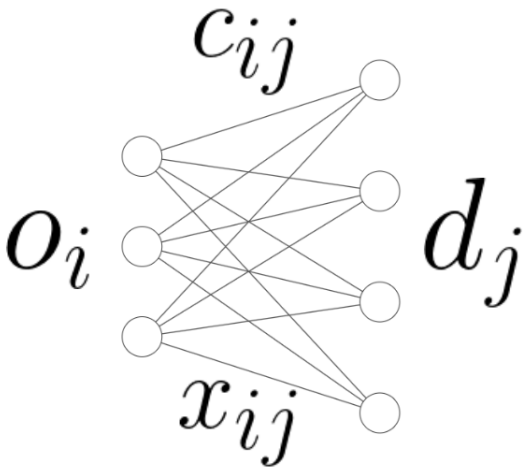

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{23} & x_{34} \end{bmatrix} \quad C = \begin{bmatrix} c_{11} & c_{12} & c_{13} & c_{14} \\ c_{21} & c_{22} & c_{23} & c_{24} \\ c_{31} & c_{32} & c_{23} & c_{34} \end{bmatrix}$$

$$O = \begin{bmatrix} o_1 \\ o_2 \\ o_3 \end{bmatrix} \qquad D = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ d_4 \end{bmatrix}$$

- Oi = cantidad a ofertar por nodo i
- Dj = cantidad a demandar por nodo j
- Cij = costo de transporte entre i y j
- **Xij = cantidad a transportar entre i y j**

Figure: Caso de transporte

Programacion lineal: transporte

Función objetivo

$$Z = \sum_{i=1}^{3} \sum_{i=1}^{4} \mathbf{c}_{ij} \mathbf{x}_{ij}$$

restricciones: toda la oferta de los orígenes "a" debe ser igual a toda la demanda de los destinos "b".

$$\sum_{i=1}^{3} a_i = \sum_{j=1}^{4} b_j$$

Para generalizar podemos decir tanto la oferta como la demanda de todos los orígenes y destinos estará distribuida en la matriz X.

$$\begin{cases} \sum_{i=1}^{4} x_{ij} = a_i \quad , i = (1,2,3) \\ \sum_{i=1}^{3} x_{ij} = b_j, j = (1,2,3,4) \end{cases}$$

Programacion lineal: transporte

$$\min z = c_{11}x_{11} + c_{12}x_{12} + c_{13}x_{13} + c_{14}x_{14} +$$
$$c_{21}x_{21} + c_{22}x_{22} + c_{23}x_{23} + c_{24}x_{24} + c_{31}x_{31} + c_{32}x_{32} +$$
$$c_{33}x_{33} + c_{34}x_{34}$$
$$x_{11} + x_{12} + x_{13} + x_{14} = o_1$$
$$x_{21} + x_{22} + x_{23} + x_{24} = o_2$$
$$x_{31} + x_{32} + x_{33} + x_{34} = o_3$$
$$x_{11} + x_{21} + x_{31} = d_1$$
$$x_{12} + x_{22} + x_{32} = d_2$$
$$x_{13} + x_{23} + x_{33} = d_3$$
$$x_{14} + x_{24} + x_{34} = d_4$$

Programación lineal: transporte

$$
\begin{aligned}
464x_{11} + 513x_{12} + 654x_{13} + 867x_{14} \\
\min \mathrm{z} = +352x_{21} + 416x_{22} + 690x_{23} + 791x_{24} \\
+995x_{31} + 682x_{32} + 388x_{33} + 685x_{34} \\
x_{11} + x_{12} + x_{13} + x_{14} = 75 \\
x_{21} + x_{22} + x_{23} + x_{24} = 125 \\
x_{31} + x_{32} + x_{33} + x_{34} = 100 \\
x_{11} + x_{21} + x_{31} = 80 \\
x_{12} + x_{22} + x_{32} = 65 \\
x_{13} + x_{23} + x_{33} = 70 \\
x_{14} + x_{24} + x_{34} = 85
\end{aligned}
$$

Programación lineal: transporte

Resolver este problema computacionalmente

Existen solvers de Optimización Lineal y Entera/binaria como la libreria PICOS (`https://pypi.org/project/PICOS/PulP`) o la libreria PulP (`https://coin-or.github.io/pulp/main/includeme.html`).

Nocedal, J., & Wright, S. J. (Eds.). (1999). Numerical optimization. New York, NY: Springer New York.

Strang, G. (2019). Linear algebra and learning from data (Vol. 4). Cambridge: Wellesley-Cambridge Press.