Métodos Numéricos y Optimización
Lecture 22: Optimización

Martín Palazzo

Universidad de San Andrés
Ingeniería en Inteligencia Artificial

palazzom@udesa.edu.ar

June 12, 2024

Overview

1. Line Search methods
2. Optimización de 2do orden: Newton
3. Optimización de 1er orden: Gradiente descendiente
4. Optimizando con Gradiente descendiente
5. Convergencia del Gradiente descendiente
6. Gradiente descendiente con Momentum

Line Search methods

Optimizacion: Line Search methods

Hemos visto que la estructura de un método de optimización *Line Search* implica ir iterando distintas soluciones x_k de manera tal que

$$f(x_{k+1}) < f(x_k)$$

avanzando iterativamente en la dirección p_k a un *step lenght* de s_k

$$\min_{\alpha>0} f\left(x_k + s_k p_k\right)$$

entonces el problema iterativo se expresa como

$$x_{k+1} = x_k - s_k p$$

donde esta metodología aplica cuando tenemos un problema de optimización tanto convexo como no convexo.

Optimización: Line Search methods

Line search methods

Estudiaremos dos alternativas para encontrar la dirección de búsqueda p_k

- Método de primer orden: gradiente descendiente.
- Método de segundo orden: Método de Newton.

Optimización de 2do orden: Newton

Método de Newton

Suponer que $x \in \mathbb{R}^n$, buscamos el argumento mínimo x^* donde $f(x)$ es mínima y su gradiente

$$\nabla f(x) = 0$$

donde el gradiente de $f(x_1, x_2, \ldots, x_n)$ es el vector columna

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n} \right)$$

Método de Newton

para llegar a

$$\nabla f(x) = 0$$

partiendo de un punto x_k la función del gradiente $\nabla f(x)$ en un vecindario cercano puede estimarse utilizando las derivadas primeras, que en este caso es la derivada segunda de $f(x)$. Las derivadas segundas parciales

$$\frac{\partial^2 f}{\partial x_i \partial x_j}$$

forman la matriz *Hessiano* H donde

$$H = \nabla(\nabla f(x))$$

entonces

$$\nabla f(x_{k+1}) \approx \nabla f(x_k) + H(x_k)(x_{k+1} - x_k)$$

Método de Newton

de la slide anterior

$$\nabla f(x_{k+1}) \approx \nabla f(x_k) + H(x_k)(x_{k+1} - x_k)$$

queremos que el lado izquierdo de la ecuación sea $\nabla f(x_{k+1}) = 0$ entonces la elección de x_{k+1} (dirección p_k) va a definirse cuando el lado derecho sea

$$\nabla f(x_k) + H(x_k)(x_{k+1} - x_k) = 0$$

entonces que para el paso $\Delta x_k = x_{k+1} - x_k$ hay n ecuaciones a resolver quedando

$$H(x_k)(\Delta x_k) = -\nabla f(x_k)$$

Método de Newton

de la slide anterior

Optimización con Método de Newton

hay que resolver

$$H(x_k)(\Delta x_k) = -\nabla f(x_k) \tag{1}$$

y actualizar

$$x_{k+1} = x_k + \Delta x_k$$

nos remite al método de Newton para búsqueda de raíces

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Método de Newton

desde una perspectiva de series de Taylor de segundo orden la dirección de búsqueda de Newton p_k^{N}

$$x_{k+1} = x_k + \Delta x_k$$

es aquella que minimiza la función cuadrática

$$f\left(x_k + \Delta x_k\right) \approx f(x_k) + \nabla f(x_k)^t (x - x_k) + \frac{1}{2}(x - x_k)^t h(x_k)(x - x_k)$$

Asumiendo que H es positiva definida si buscamos llevar la derivada de $f(x_k + \Delta x_k)$ a 0 tal que $\nabla f(x_k + \Delta x_k) = 0$
llegamos a la expresión de la dirección de Newton

$$p_k^{\mathrm{N}} = -\left(\nabla^2 f(x_k)\right)^{-1} \nabla f(x_k)$$

Método de Newton

Convergencia del método de Newton

$$\|x_{k+1} - x^*\| \leq C\|x_k - x^*\|^2$$

La convergencia de búsqueda del óptimo en el método de Newton es cuadrática.

Método de Newton

Supongamos que tenemos la función $f(x) = \frac{1}{3}x^3 - 4x$

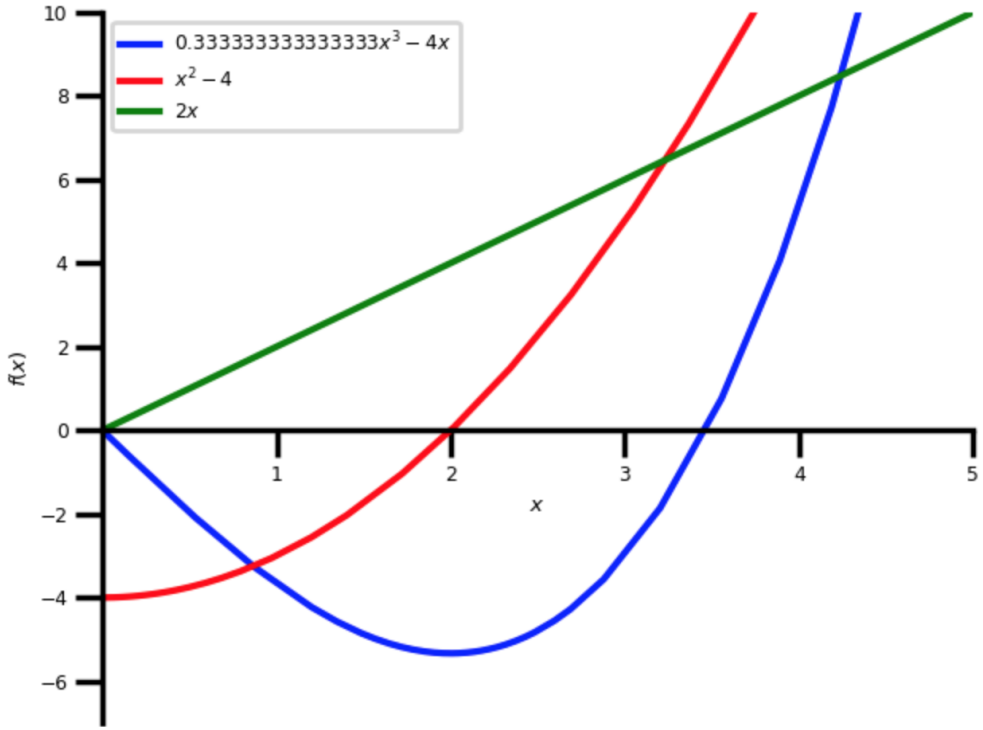

Figure: Funcion a optimizar

donde su gradiente $\nabla f(x) = x^2 - 4$ y su hessiano $H(x) = 2x$

Método de Newton

de la ecuación (1)

$$H(x_k)(\Delta x_k) = -\nabla f(x_k)$$

y de los datos del problema

$$\begin{aligned} f(x) =& \frac{1}{3}x^3 - 4x \\ \nabla f(x) =& x^2 - 4 \\ H(x) =& 2x \end{aligned}$$

entonces para encontrar la dirección de búsqueda de Newton

$$\begin{aligned} 2x_k(x_{k+1} - x_k) &= -x_k^2 + 4 \\ 2x_k x_{k+1} &= -x_k^2 + 4 \\ x_{k+1} =& \frac{1}{2}\left(x_k + \frac{4}{x_k}\right) \end{aligned}$$

Método de Newton

si nuestra *semilla* inicial es $x_0 = 2.5$ la secuencia de soluciones en cada iteración sera

$$x_0 = 2.5$$
$$x_1 = 2.05$$
$$x_2 = 2.0006$$
$$x_3 = 2.000000009$$

Método de Newton

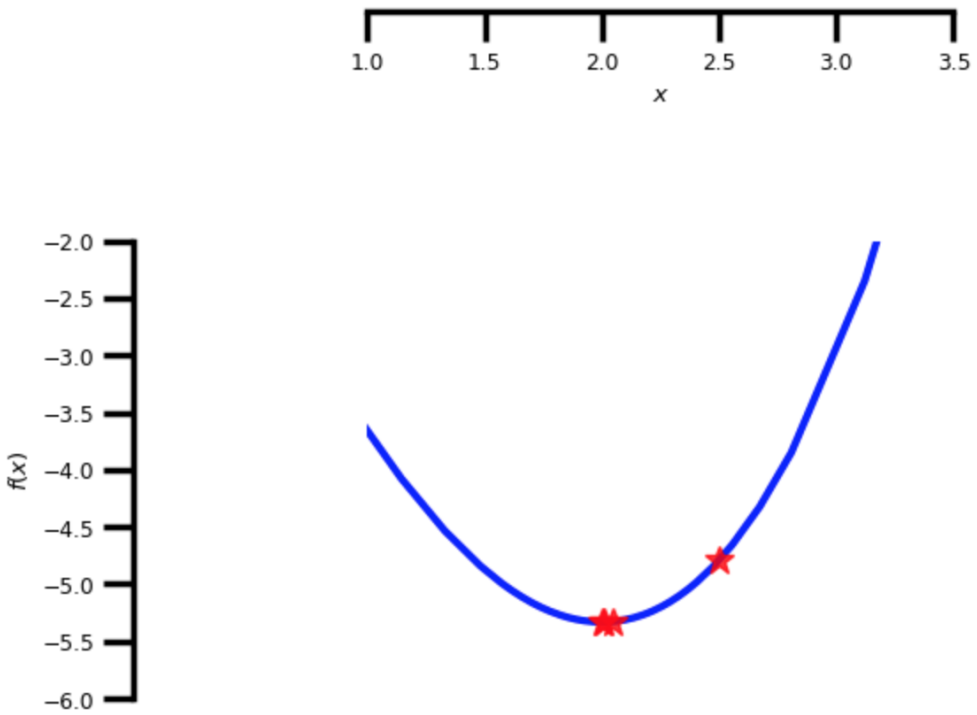

Figure: Cada estrella es una solución en cada iteración

El método de Newton converge rápido gracias al uso de derivadas segundas. De todos modos, en alta dimensión computar el Hessiano puede ser caro.

Optimización de 1er orden: Gradiente descendiente

Gradiente descendiente

Gradiente descendiente

Podemos usar $-\nabla f(x)$ para minimizar

$$\min_x f(x)$$

sin restricciones y resolver $\nabla f(x) = 0$ de forma iterativa con

$$x_{k+1} = x_k - s_k \nabla f(x_k)$$

donde s_k lo llamamos *step size* o *learning rate*.

Gradiente descendiente: interpretación geométrica

Supongamos que $x \in \mathbb{R}^{n=2}$. Su gradiente entonces

$$\nabla f(x) = (\partial f/\partial x_1, \partial f/\partial x_2)$$

donde este vector cambia su modulo a medida que la solución se mueve por el dominio quedando

$$\|\nabla f(x)\| = \sqrt{\left(\frac{\partial f}{\partial x_1}\right)^2 + \left(\frac{\partial f}{\partial x_2}\right)^2}$$

y es la magnitud de la dirección de máximo crecimiento

Gradiente descendiente: interpretación geométrica

Supongamos la función

$$f(x_1, x_2) = ax_1^2 + bx_2^2$$

cuyo gradiente

$$\nabla f(x) = \begin{bmatrix} 2ax_1 \\ 2bx_2 \end{bmatrix}$$

y en el mínimo $\nabla f(x_1, x_2) = (2ax_1, 2bx_2) = (0, 0)$. El gradiente detallado previamente cambia a medida nos vamos moviendo por el dominio y no necesariamente apunta directamente al mínimo!

Gradiente descendiente: interpretación geométrica

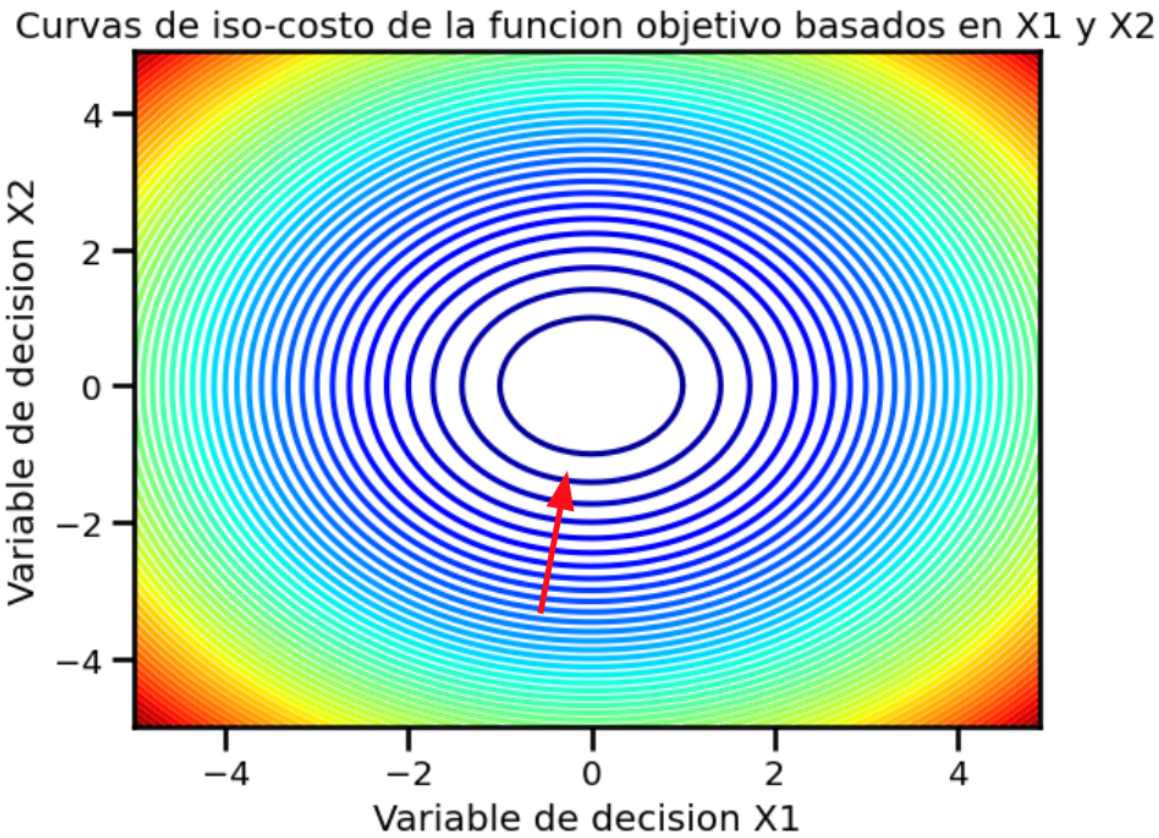

Figure: Dado un $f(x) = \mathrm{C}$ constante, la dirección de la curva de nivel es perpendicular al vector de gradiente

Si $f(x_1, x_2) = \frac{1}{2}(x_1^2 + x_2^2)$ en cualquier punto del dominio el gradiente apunta directamente al mínimo.

Gradiente descendiente: interpretación geométrica

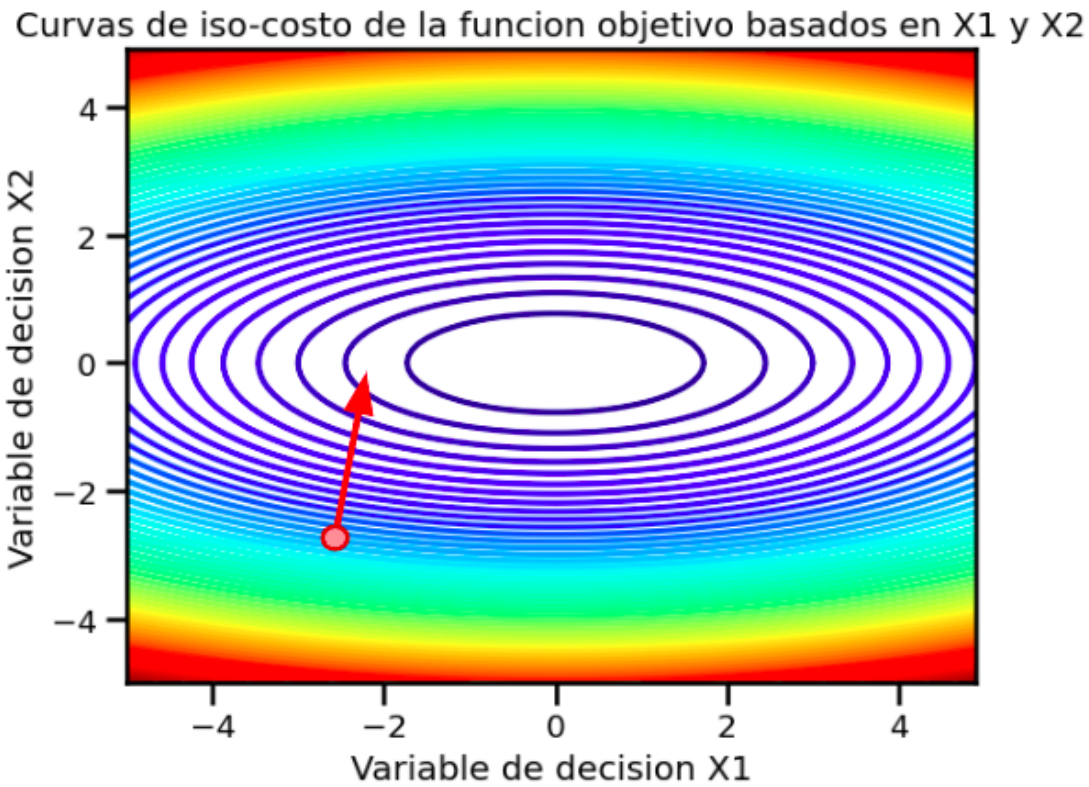

Figure: Dado un $f(x) = C$ constante, la dirección de la curva de nivel es perpendicular al vector de gradiente

Si $f(x_1, x_2) = \frac{1}{2}(x_1^2 + 5x_2^2)$ el gradiente no necesariamente apunta al mínimo.

Gradiente descendiente: interpretación geométrica

Ejemplo en una función cuadrática

Por ejemplo si la función f con $0 \leq b \leq 1$

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + bx_2^2)$$

donde el mínimo $(x_1^* = 0, x_2^* = 0)$. Como elegimos s_k? Una estrategia es *Exact Line Search* donde buscamos s_k que minimiza f.

Gradiente descendiente: interpretación geométrica

Una estrategia es *Exact Line Search* donde buscamos s_k que minimiza f.
Si $f(x_1, x_2) = \frac{1}{2}(x_1^2 + bx_2^2)$

$$\nabla f(x) = \begin{bmatrix} x_1 \\ bx_2 \end{bmatrix}$$

entonces

$$\begin{aligned} x_{1(k+1)} =& x_{1(k)} - s_k \cdot x_{1(k)} = x_{1(k)}(1 - s_k) \\ x_{2(k+1)} =& x_{2(k)} - s_k \cdot b \cdot x_{2(k)} = x_{2(k)}(1 - b \cdot s_k) \end{aligned}$$

quedando la función en $x_{(k+1)}$

$$f\left(x_{1(k+1)}, x_{2(k+1)}\right) = \frac{1}{2}\left((x_{1k})^2(1 - s_k)^2 - b \cdot (x_{2k})^2(1 - b \cdot s_k)^2\right)$$

Gradiente descendiente: interpretación geométrica

de la slide anterior

$$f\left(x_{1(k+1)}, x_{2(k+1)}\right) = \frac{1}{2}\left((x_{1\,k})^2(1-s_k)^2 - b\cdot(x_{2\,k})^2(1-b\cdot s_k)^2\right)$$

el gradiente respecto de s_k

$$\frac{\partial f}{\partial s_k}\left(x_{1(k+1)}, x_{2(k+1)}\right) = -x_{1\,k}^2\cdot(1-s_k) - b^2\cdot x_{2\,k}^2\cdot(1-b\cdot s_k)$$

Gradiente descendiente: interpretación geométrica

de la slide anterior el gradiente respecto de s_k

$$\frac{\partial f}{\partial s_k}\left(x_{1(k+1)}, x_{2(k+1)}\right) = -{x_1}_k^2 \cdot (1 - s_k) - b^2 \cdot {x_2}_k^2 \cdot (1 - b \cdot s_k)$$

entonces si

$$\frac{\partial f}{\partial s_k}\left(x_{1(k+1)}, x_{2(k+1)}\right) = 0$$

llegamos a la solución s_k

$$S_k = \frac{{x_1}_k^2 + b^2 {x_2}_k^2}{{x_1}_k^2 + b^3 {x_2}_k^2}$$

Gradiente descendiente: interpretación geométrica

de la slide anterior

$$S_k = \frac{{x_1}_k^2 + b^2 {x_2}_k^2}{{x_1}_k^2 + b^3 {x_2}_k^2}$$

si $(x_{1(k=0)}, x_{2(k=0)}) = (b, 1)$

$$s_0 = \frac{2}{1+b}$$

podemos calcular entonces los nuevos puntos en $k = 1$

$$x_{1(k+1)} = x_{1(k)}(1 - s_k) \rightarrow x_{1(k=1)} = b \cdot (1 - s_0) = b\left(\frac{b-1}{b+1}\right)$$

$$x_{2(k+1)} = x_{2(k)}(1 - b \cdot s_k) \rightarrow x_{2(k=1)} = (1 - b \cdot s_0) = \left(\frac{1-b}{1+b}\right)$$

Gradiente descendiente: interpretación geométrica

de la slide anterior

$$x_{1(k+1)} = x_{1(k)}(1 - s_k) \rightarrow x_{1(k=1)} = b \cdot (1 - s_0) = b\left(\frac{b-1}{b+1}\right)$$

$$x_{2(k+1)} = x_{2(k)}(1 - b \cdot s_k) \rightarrow x_{2(k=1)} = (1 - b \cdot s_0) = \left(\frac{1-b}{1+b}\right)$$

entonces si la semilla $(x_{1(k=0)}, x_{2(k=0)}) = (b, 1)$ de la función objetivo $f(x_1, x_2) = \frac{1}{2}(x_1^2 + bx_2^2)$ generalizando a mas iteraciones llegamos a

$$x_{1(k)} = b \cdot \left(\frac{b-1}{b+1}\right)^k, \quad x_{2(k)} = \left(\frac{1-b}{1+b}\right)^k$$

Gradiente descendiente: interpretación geométrica

de la slide anterior

$$x_{1(k)} = b \cdot \left(\frac{b-1}{b+1}\right)^k, \quad x_{2(k)} = \left(\frac{1-b}{1+b}\right)^k$$

podemos obtener analíticamente el valor de la función objetivo en cada paso k partiendo de cualquier semilla $x_{(k=0)}$

$$f\left(x_{1(k)}, x_{2(k)}\right) = \left(\frac{1-b}{1+b}\right)^{2k} f\left(x_{1(k=0)}, x_{2(k=0)}\right)$$

entonces si $b = \frac{1}{2}$ entonces $x_{1(k)} = \frac{1}{2}\left(\frac{-1}{3}\right)^k$ en cada iteración

$$x_{1(k=0)=\frac{1}{2}}, x_{1(k=1)=\frac{-1}{6}} \quad , x_{2(k=2)=\frac{1}{18}}$$

es decir que "va y viene"!!!

Gradiente descendiente: interpretación geométrica

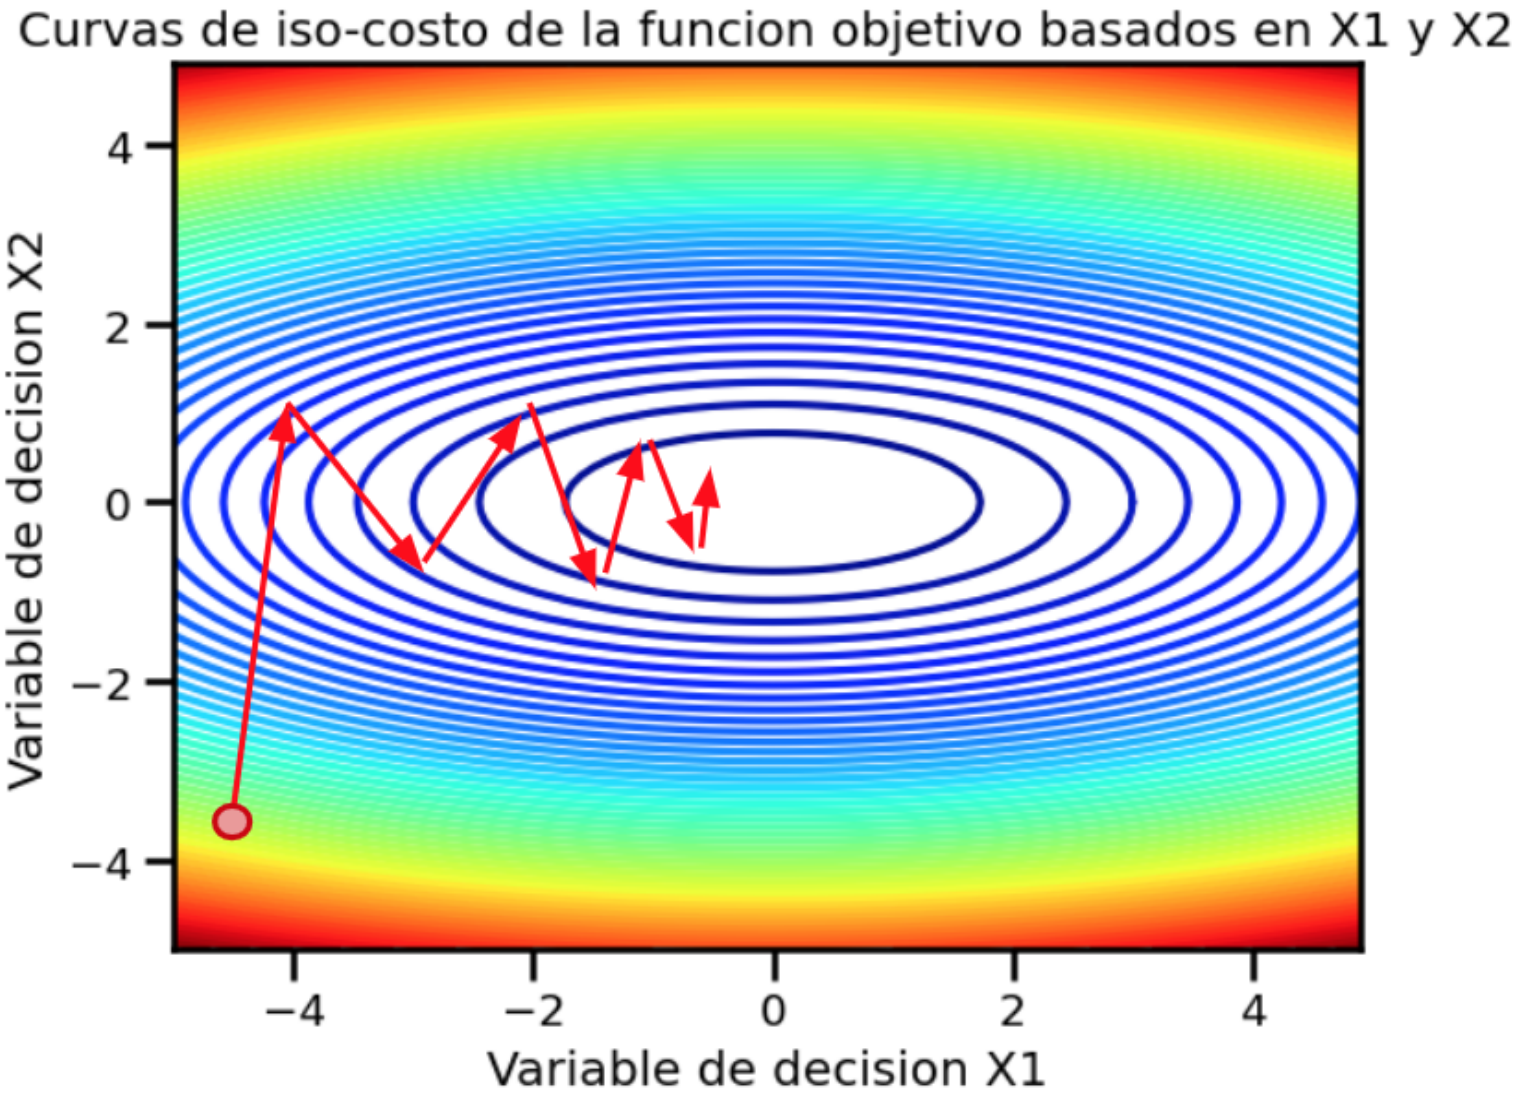

Figure: Convergencia al óptimo con zig-zag

Optimizando con Gradiente descendiente

Optimización de 1er orden: gradiente descendiente

Si

$$f(x) = x^2$$

y el $s_k = 0.8$ entonces partiendo de una *semilla* x_0

$$\begin{aligned} x_0 &= -4 \\ x_1 &= -4 - 0.8 \cdot 2 \cdot (-4) = 2.4 \\ x_2 &= 2.4 - 0.8 \cdot 2 \cdot 2.4 = -1.44 \\ x_3 &= 0.864 \end{aligned}$$

hasta llegar a una convergencia

$$\|x_{k+1} - x_k\| < \epsilon$$

Optimización de 1er orden: gradiente descendiente

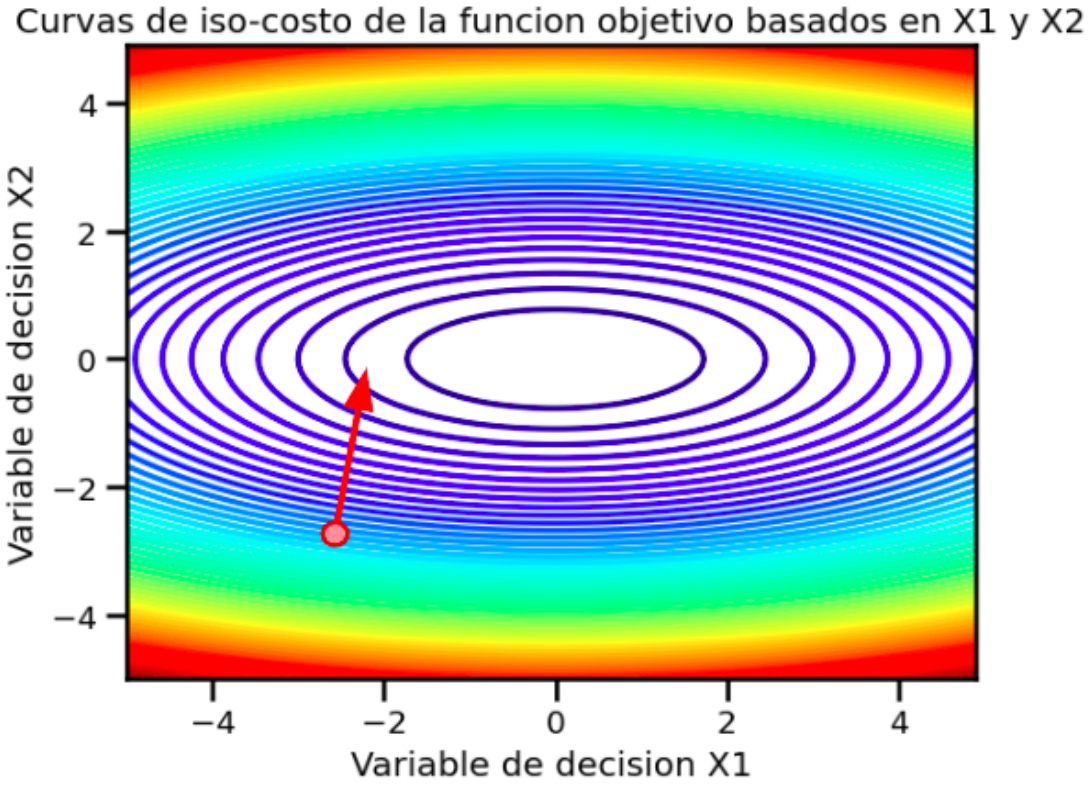

Figure: Gradiente desde x_0

Notar que el gradiente es ortogonal a las curvas de *iso-costo*. De todas maneras, no siempre el gradiente va a direccionar directamente hacia el mínimo!

Optimización de 1er orden: gradiente descendiente

Como decidimos por S_k

- un stepsize muy chico: tardamos en converger
- un stepsize muy grande: hay riesgo de no converger (saltar los minimos locales)

Caso Cuadrados Mínimos con GD

$$\min_{w} \; L(y, \hat{y}) = \min_{w} \; L(y, \hat{f}(x))$$

siendo $\hat{f}(x)$ la función lineal

$$f(x) = w^t x = y$$

donde los parámetros $w \in \mathbb{R}^n$ son las incógnitas. Es decir, hay tantos parámetros como dimensionalidad tenga el problema.

Caso Cuadrados Mínimos con GD

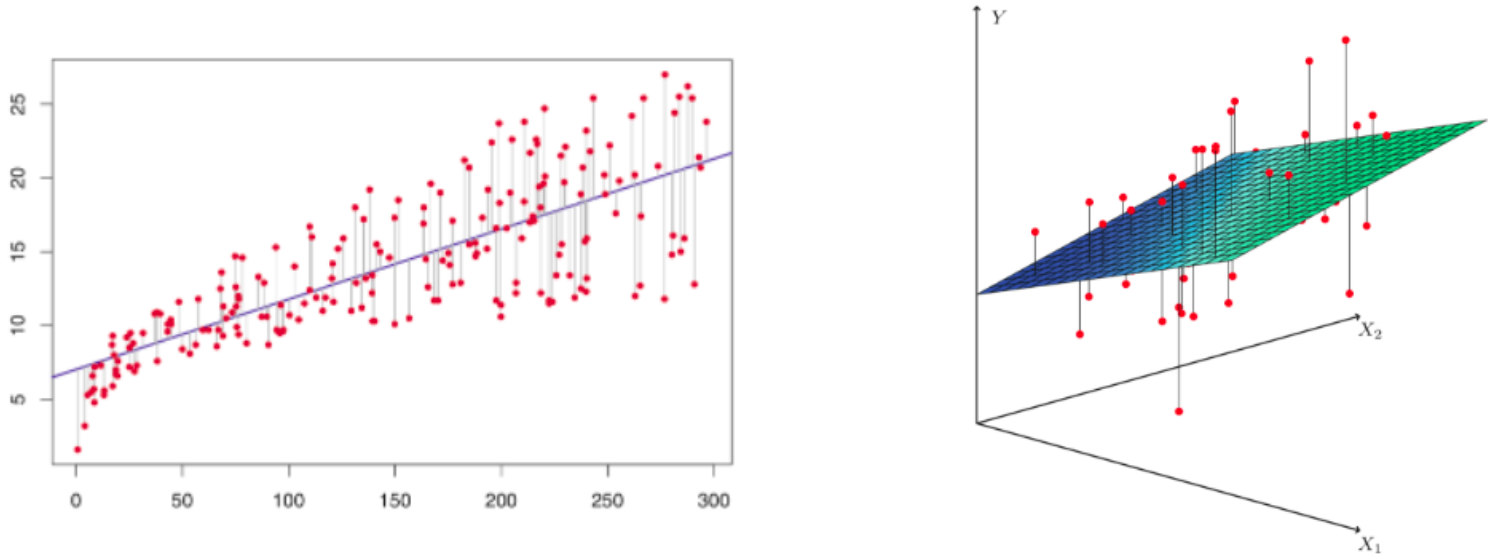

Figure: Regresión lineal: Cuadrados mínimos ordinarios

$$f(x) = w^t x = y$$

Caso Cuadrados Mínimos con GD

La suma de los residuos al cuadrado (RSS = Residual squared sums) es la función objetivo y se escribe

$$\mathrm{RSS}(w) = L(w) = \sum_i^n (y_i - f(x_i))^2$$

$$\mathrm{RSS}(w) = L(w) = \sum_i^n \left(y_i - w_0 - \sum_j^d x_{ij} w_j\right)^2$$

que es equivalente a minimizar la norma

$$\min_w \|Xw - y\|^2$$

Gradiente descendiente para Least squares

Si tenemos el dataset

x	y
164	83.3
135	76.7
190	85
180	90
189	94.5
155	77.1
163	81.5
178	89
173	86.5
176	88

cuanto deberia valer w para minimizar

$$\min_{w} \|Xw - y\|^2$$

Gradiente descendiente para Least squares

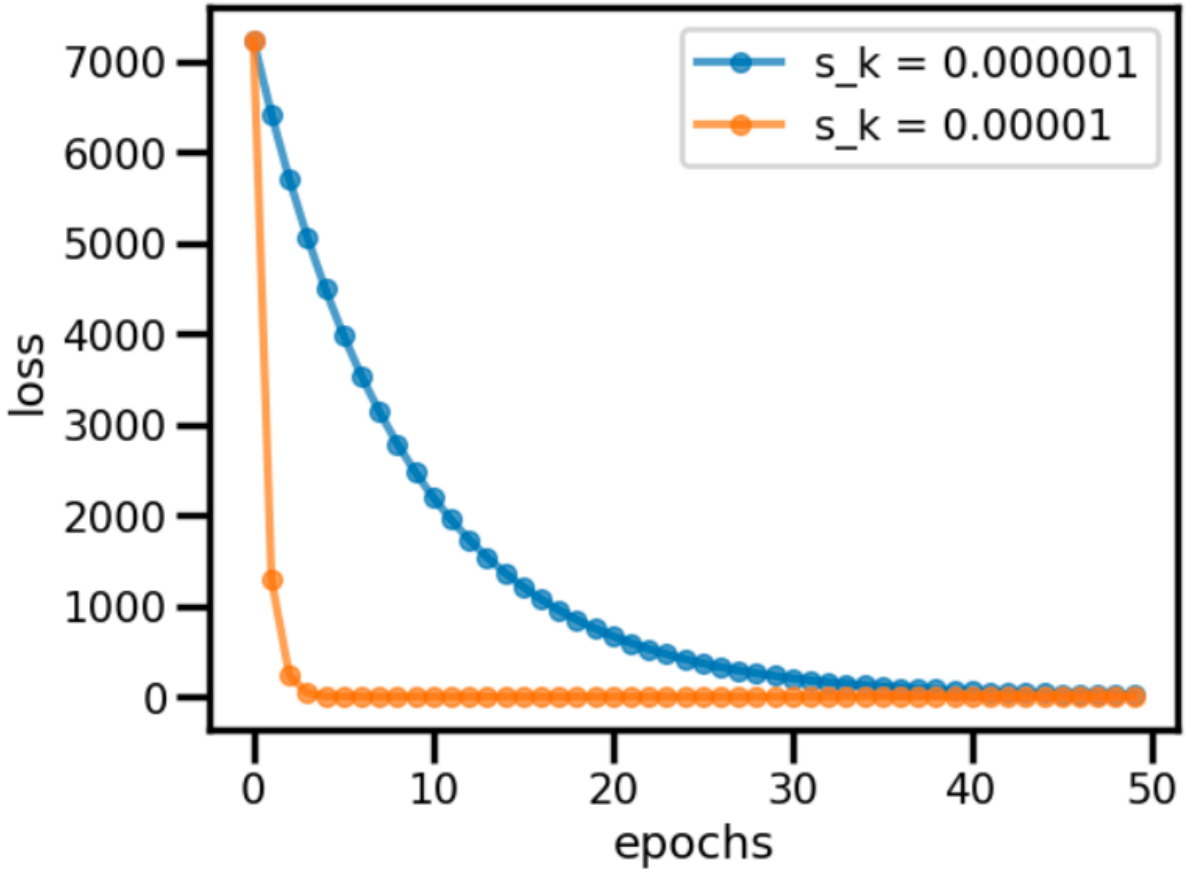

Figure: Funcion objetivo para las soluciones iterativas de GD.

Gradiente descendiente para Least squares

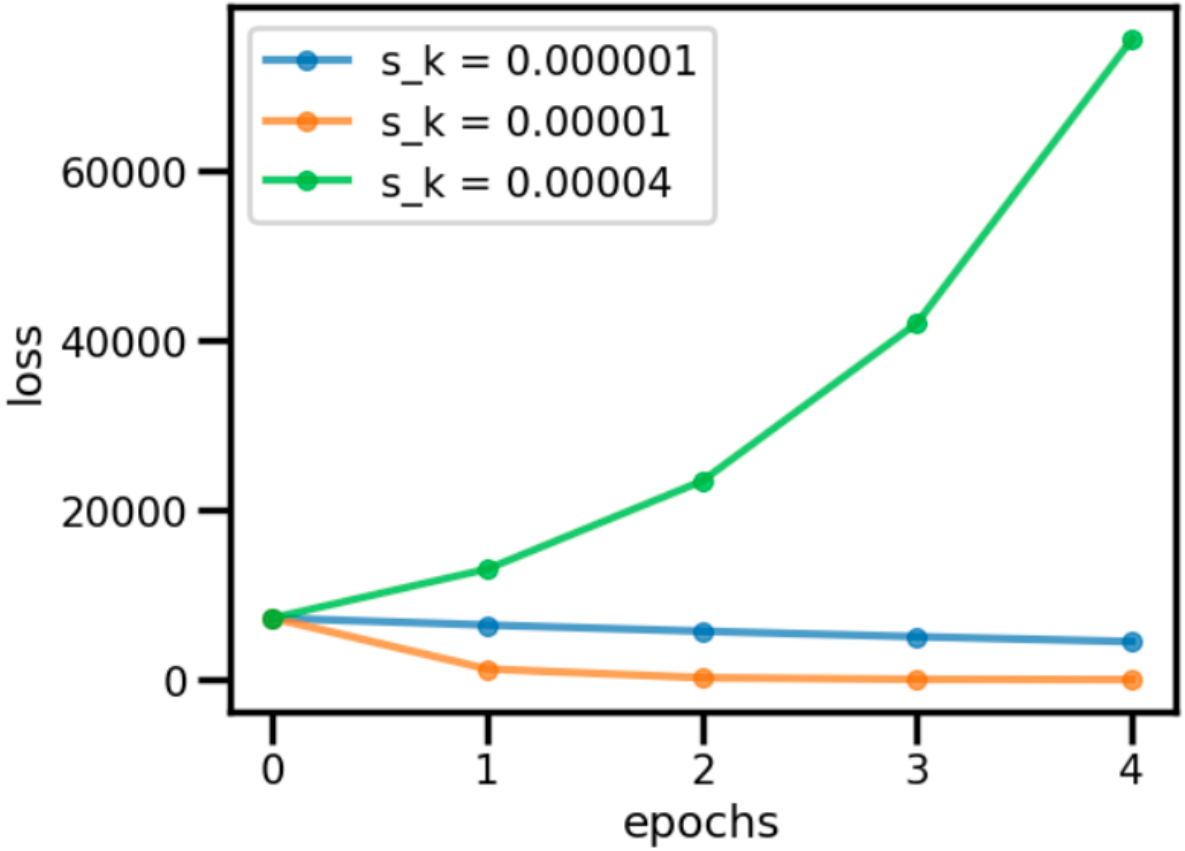

Figure: Funcion objetivo para las soluciones iterativas de GD.

Un learning rate muy alto puede resultar en divergencia.

Convergencia del Gradiente descendiente

Gradiente descendiente: convergencia

Supongamos la función objetivo f convexa, con Hessiano definido positivo

$$f(x_1, x_2) = \frac{1}{2}(x_1^2 + bx_2^2)$$

y su Hessiano

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

es diagonal, donde sus derivadas segundas parciales son 1 y b. Además H tiene autovalores entre

$$m \leq \lambda \leq M$$

donde en el ejemplo anterior $m = b$ y $M = 1$. Los dos autovalores de H son $m = b$ y $M = 1$.

Gradiente descendiente: convergencia

si realizamos una expansión de Taylor cuadrática sobre x_k

$$f\left(x_{k+1}\right) \approx f(x_k) + \nabla f(x_k)^t (x_{k+1} - x_k) + \frac{1}{2}(x_{k+1} - x_k)^t h(x_k)(x_{k+1} - x_k)$$

se cumple que el Hessiano es una función de Lipschitz con constante M

$$\|\nabla(\nabla f(x_k)) - \nabla(\nabla f(x_{k+1}))\|_2 \leq M\|x_k - x_{k+1}\|_2$$

reescribimos

$$f\left(x_{k+1}\right) \leq f(x_k) + \nabla f(x_k)^t (x_{k+1} - x_k) + \frac{M}{2}\|x_{k+1} - x_k\|^2$$

Gradiente descendiente: convergencia

de la slide anterior

$$f\left(x_{k+1}\right) \leq f(x_k) + \nabla f(x_k)^t (x_{k+1} - x_k) + \frac{M}{2}\|x_{k+1} - x_k\|^2 \tag{2}$$

recordando que

$$x_{k+1} = x_k - s_k \nabla f(x_k)$$

expresamos

$$f\left(x_{k+1}\right) \leq f(x_k) - s\|\nabla f(x_k)\|^2 + \frac{M \cdot s^2}{2}\|\nabla f(x_k)\|^2$$

Gradiente descendiente: convergencia

de la slide anterior

$$f\left(x_{k+1}\right) \leq f(x_k) - s\|\nabla f(x_k)\|^2 + \frac{M \cdot s^2}{2}\|\nabla f(x_k)\|^2$$

sabemos por *Exact Line Search* que el mejor s minimiza el termino de la izquierda. El mínimo del lado derecho de la ecuación se obtiene con $s = 1/M$ entonces si sustituimos s

$$f\left(x_{k+1}\right) \leq f(x_k) - \frac{1}{2M}\|\nabla f(x_k)\|^2$$

por otro lado tambien se revierte el signo la desigualdad de la ecuación (2) usando m siendo valida

$$f(x^*) \geq f(x_k) - \frac{1}{2m}\|\nabla f(x_k)\|^2$$

Gradiente descendiente: convergencia

de las 2 ecuaciones de la slide anterior

$$f\left(x_{k+1}\right) \leq f(x_k) - \frac{1}{2M}\|\nabla f(x_k)\|^2$$

$$f(x^*) \geq f(x_k) - \frac{1}{2m}\|\nabla f(x_k)\|^2$$

si multiplicamos por M por m respectivamente y restando ambas ecuaciones para quitar $\|\nabla f(x_k)\|^2$ llegamos a

$$f\left(x_{k+1}\right) - f\left(x^*\right) \leqslant \left(1 - \frac{m}{M}\right)\left(f\left(x_k\right) - f\left(x^*\right)\right)$$

Gradiente descendiente: convergencia

entonces de la slide anterior

$$f\left(x_{k+1}\right)-f\left(x^{*}\right) \leqslant\left(1-\frac{m}{M}\right)\left(f\left(x_{k}\right)-f\left(x^{*}\right)\right)$$

la convergencia es lineal $c = 1 - \frac{m}{M}$ entonces

- si $\frac{m}{M} << 1$ la convergencia es lenta
- caso contrario si $\frac{m}{M} < 1$ la convergencia es mas rápida

Este enfoque nos permite modelar y entender la convergencia aunque no podemos evitar el zig-zag!

Gradiente descendiente con Momentum

Gradiente descendiente con Momentum

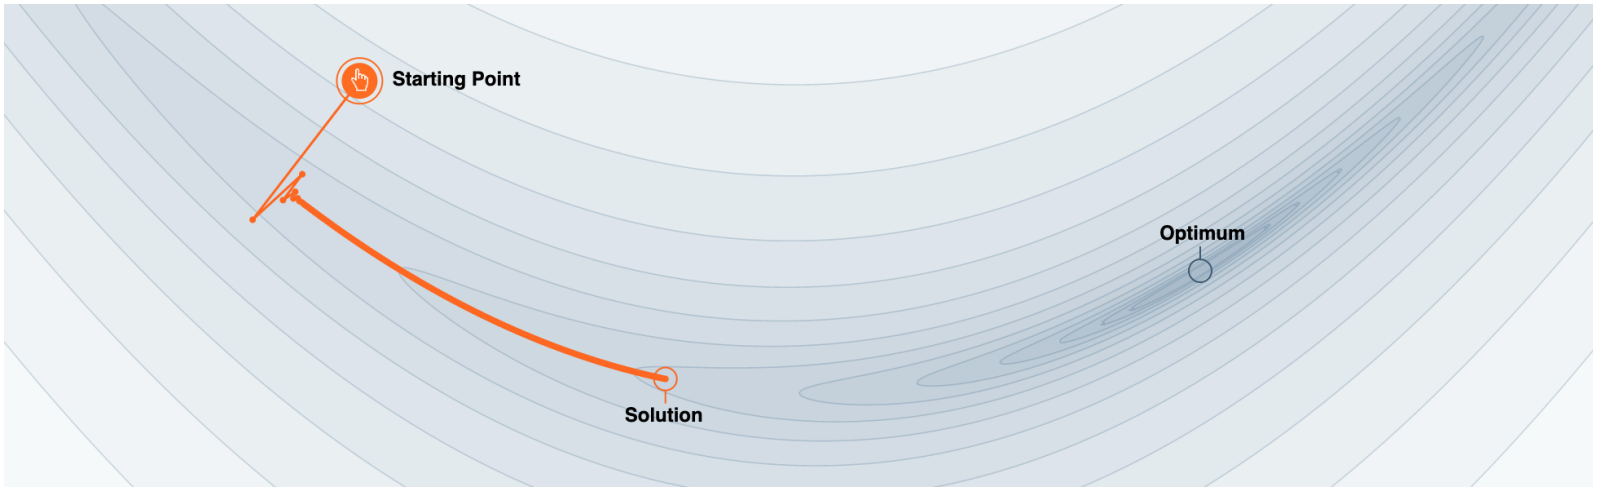

Figure: Gradiente descendiente sin momentum para un numero fijo de pasos [3].

Gradiente descendiente con Momentum

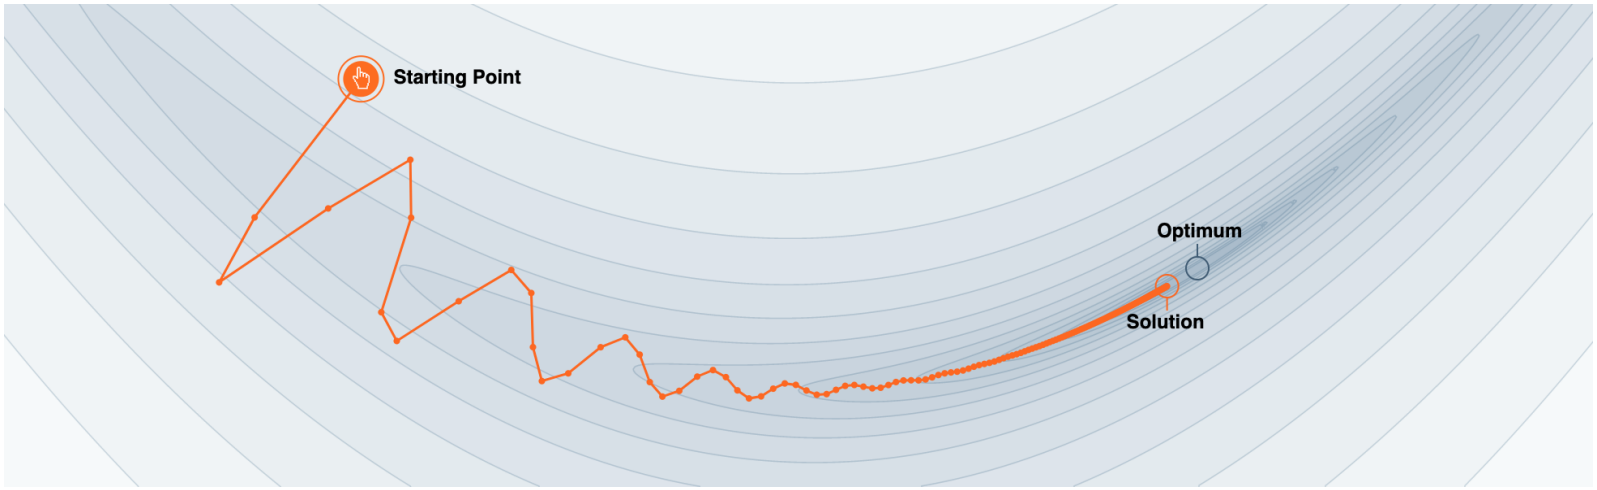

Figure: Gradiente descendiente con momentum para un numero fijo de pasos [3].

Lectura sugerida

Lecturas sugeridas

- Line search methods *Numerical Optimization* libro Nocedal Capítulo 3 [1]
- Gradiente descendiente y momentum: *Linear Algebra and Learning from Data* de Gilbert Strang capítulo y sección 6 [2]
- Momentum: *Why Momentum really works* [3]

Nocedal, J., & Wright, S. J. (Eds.). (1999). Numerical optimization. New York, NY: Springer New York.

Strang, G. (2019). Linear algebra and learning from data (Vol. 4). Cambridge: Wellesley-Cambridge Press.

Goh, G. (2017). Why momentum really works. Distill, 2(4), e6.