Métodos Numéricos y Optimización
Lecture 19: Intro a Optimización

Martín Palazzo

Universidad de San Andrés
Ingeniería en Inteligencia Artificial

palazzom@udesa.edu.ar

June 3, 2024

Overview

1. Introducción a Optimización: un mini tour
2. Funciones convexas
3. Optimización convexa

Introducción a Optimización: un mini tour

Optimización

Motivación

Dado una **función objetivo**

$$f(x) : \mathbb{R}^n \to \mathbb{R}$$

continua y diferenciable donde su dominio

$$x \in \mathbb{R}^n$$

queremos encontrar el valor de las **variables de decisión $\mathbf{x}^*$** (coordenadas) del dominio que asegura que en alguno de los casos

$$\min_x f(x) \text{ o } \max_x f(x)$$

donde la **variable de decisión $\mathbf{x}^*$** que determina el óptimo se la conoce como *Argumento Máximo* o *Argumento mínimo*

Optimización

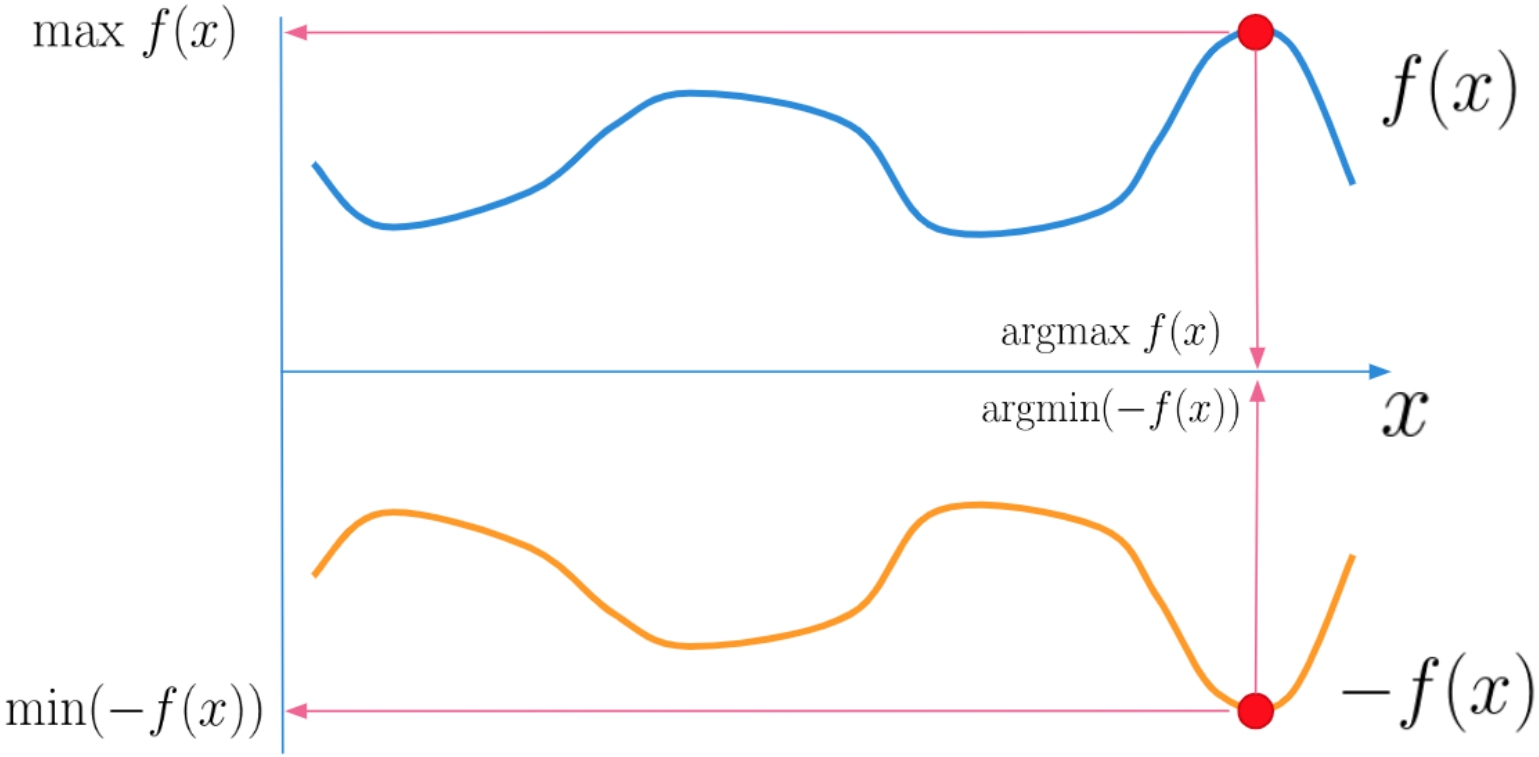

Figure: $argmin(-f(x)) = argmax(f(x))$

Optimización: restricciones

Restricciones y conjunto factible

El dominio de búsqueda puede estar acotado por

$$\begin{aligned} \text{restricciones lineales de igualdad } Ax &= b \\ \text{restricciones de desigualdad } Ax &\leq b \\ \text{restricciones de variables enteras } x_i &\in 0, 1 \end{aligned}$$

el conjunto de soluciones que satisfacen las restricciones se lo denomina **conjunto factible**

Optimización

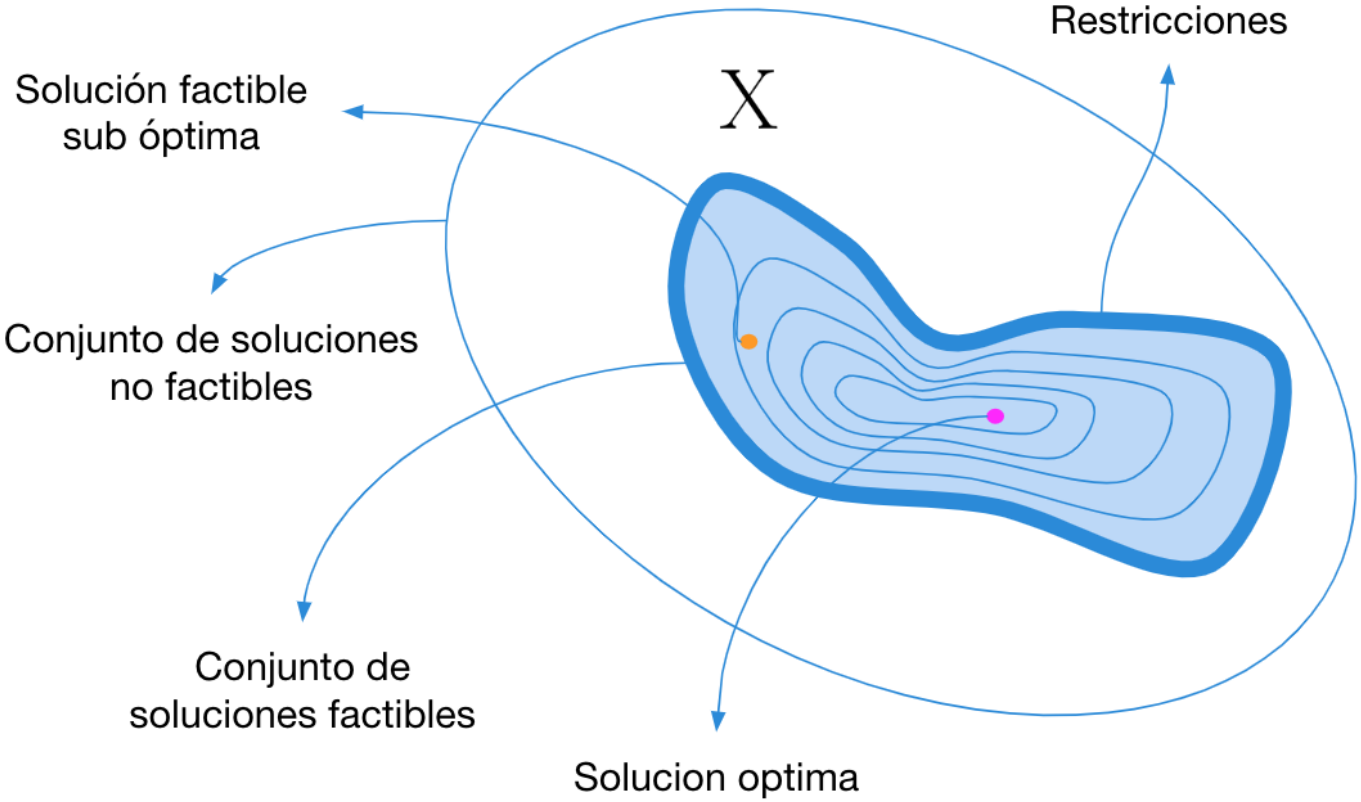

Figure: Conjunto factible

Tipos de problema de optimización

En base al tipo de función objetivo y restricciones

- Programación Lineal
- Programación cuadrática
- Programación No lineal

En base al dominio de búsqueda y la función objetivo

- Programación Convexa
- Programación No convexa

En base a sus variables de decisión

- Optimización de variables continuas
- Optimización de variables entera (Programación entera)

Programación Lineal

la función

$$f(x) : \mathbb{R}^n \to \mathbb{R}$$

es lineal, continua y diferenciable

$$f(x) = c_1 x_1 + \cdots + c_n x_n$$

$$x \in \mathbb{R}^n$$

y las restricciones del dominio

$$\begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &\leq b_1 \\ \cdots + \cdots + \ldots &\leq \ldots \\ a_{mn}x_1 + \cdots + a_{mn}x_n &\leq b_m \end{aligned}$$

Optimización: Programación lineal

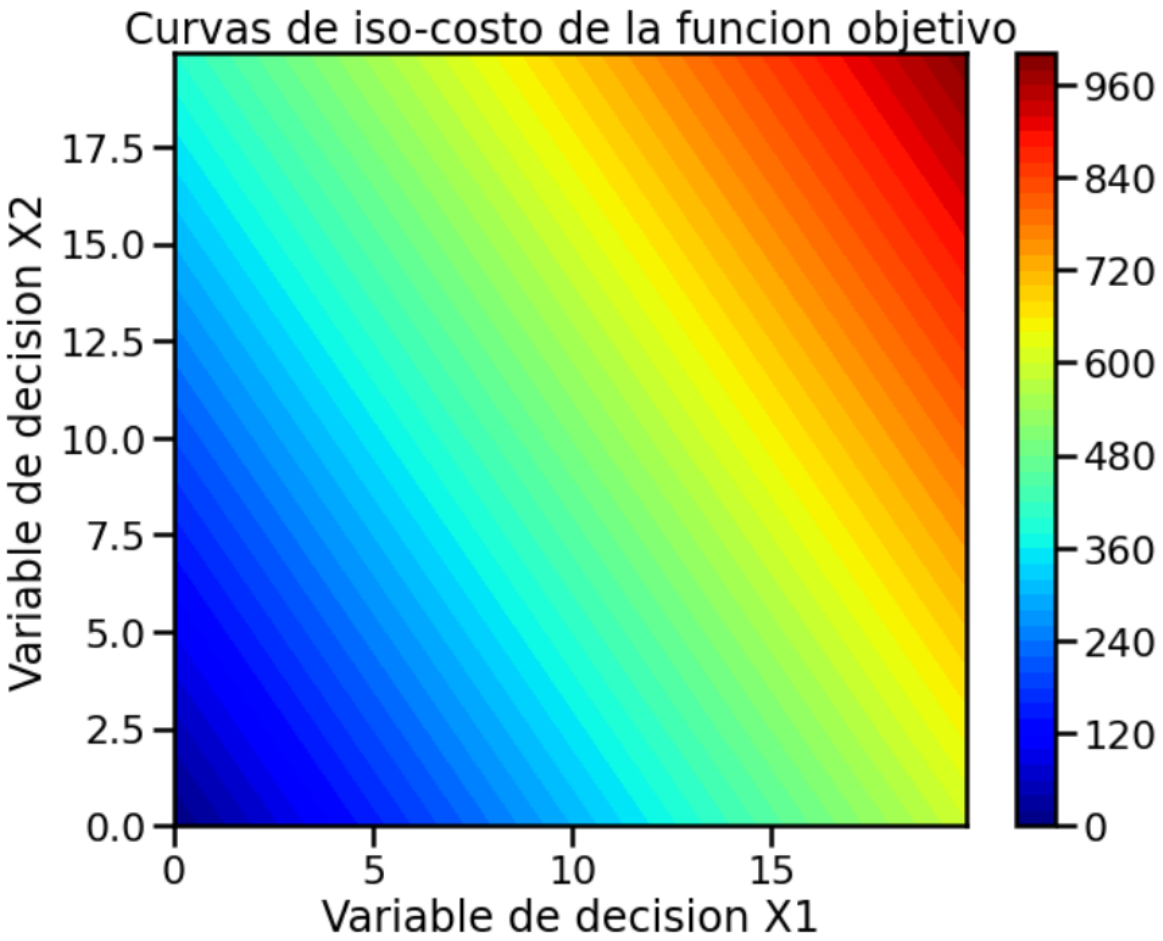

Figure: Función objetivo lineal $f(x) = 30x_1 + 20x_2$

Optimización: Programación lineal

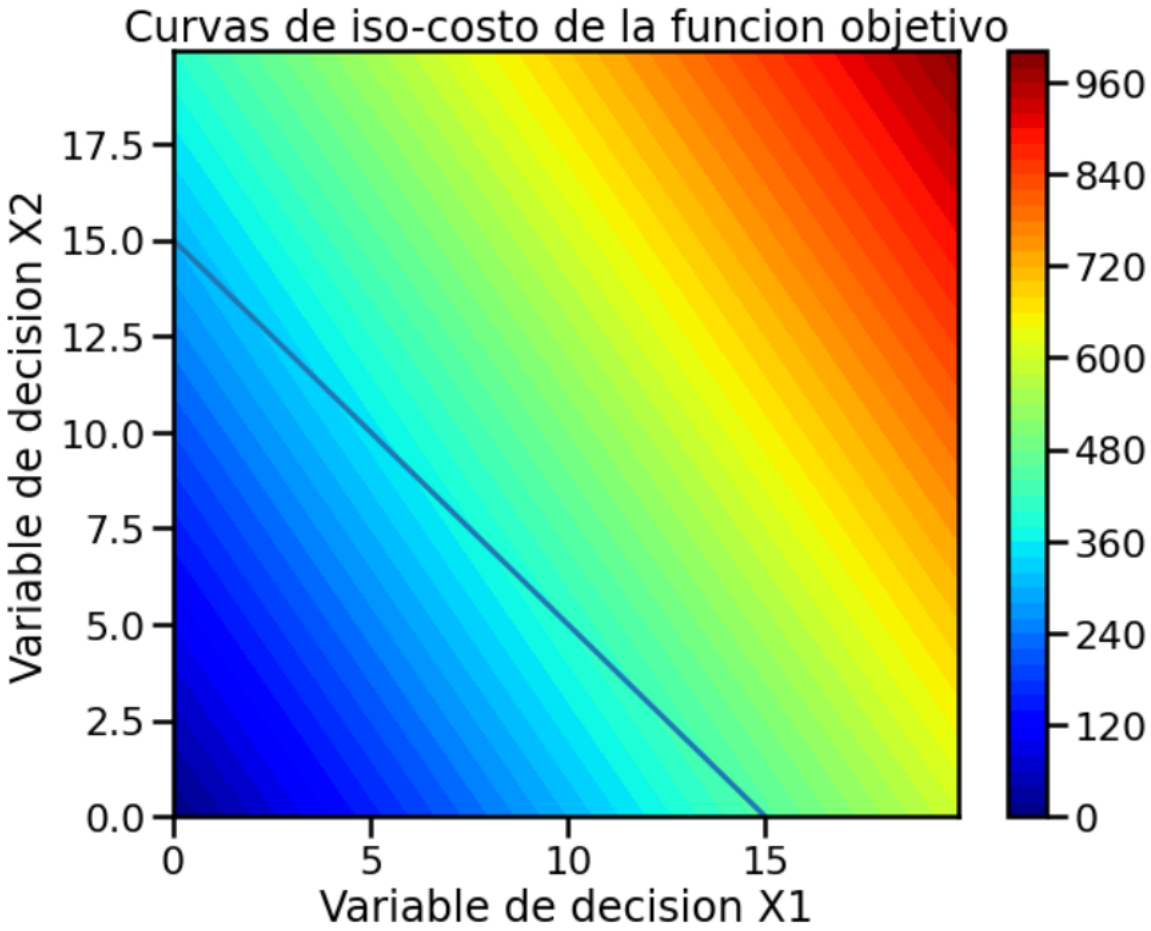

Figure: Función objetivo lineal $f(x) = 30x_1 + 20x_2$ y su restricción $x_1 + x_2 \leq 15$

Optimización: Programación lineal

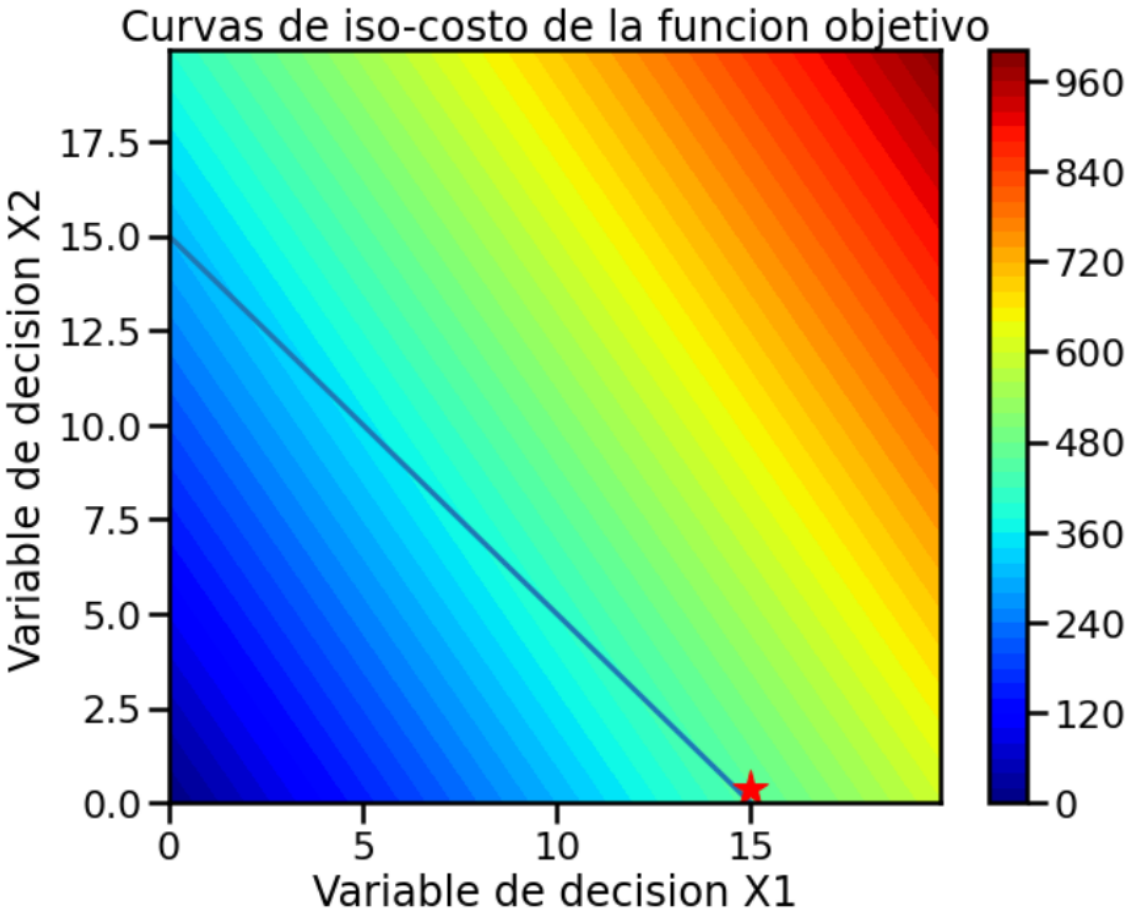

Figure: Solución **Argumento maximo** en $x^* = [15, 0]$ con máximo de $f(x^*) = 450$ de la función objetivo lineal $f(x) = 30x_1 + 20x_2$ y su restricción $x_1 + x_2 \leq 15$

Optimización: Programación Lineal

generalizando un problema de programación lineal se ve así: Función objetivo a minimizar (o maximizar según el caso)

$$\mathbf{c}^t\mathbf{x} = \mathbf{z}$$

sujeto a las restricciones

$$A\mathbf{x} \leq \mathbf{b}$$
$$\mathbf{x} \geq 0$$

con $x \in \mathbb{R}^n$.

Optimización: Programación lineal en grafos

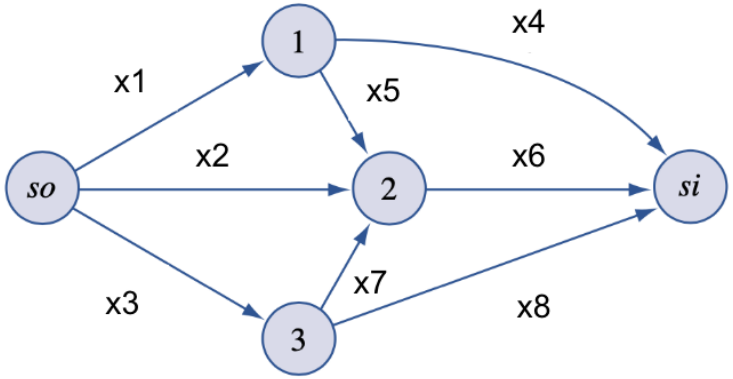

Figure: Problema de flujo máximo

Los problemas de optimización lineal (a.k.a. PL) se suelen utilizar para problemas en grafos como **máximo flujo** o **Transporte** ambos de nodos origen a nodos destino. En el caso de **máximo flujo** las variables de decisión son

$$x_{ij} \in \mathbb{R}^n$$

como la cantidad de flujo que circula por cada arco x_{ij} entre los nodos i y j de manera tal de maximizar el flujo saliente del nodo origen

$$\max \quad x_1 + x_2 + x_3$$

Optimización: Programación lineal en grafos

quedando el problema de optimización

$$\max \quad x_1 + x_2 + x_3$$

sujeto a las restricciones de balance de flujo entrante y saliente por nodo

$$\begin{aligned} x_1 &= x_5 + x_4 \\ x_2 + x_5 + x_7 &= x_6 \\ x_3 &= x_7 + x_8 \end{aligned}$$

y a restricciones capacidad de transporte por arco

$$\begin{aligned} 0 \leq x_1 &\leq b_1 \\ 0 \leq x_2 &\leq b_2 \\ 0 \leq x_3 &\leq b_3 \\ 0 \leq x_4 &\leq b_4 \\ 0 \leq x_5 &\leq b_5 \\ 0 \leq x_6 &\leq b_6 \\ 0 \leq x_7 &\leq b_7 \\ 0 \leq x_8 &\leq b_8 \end{aligned}$$

Optimización: Programación entera

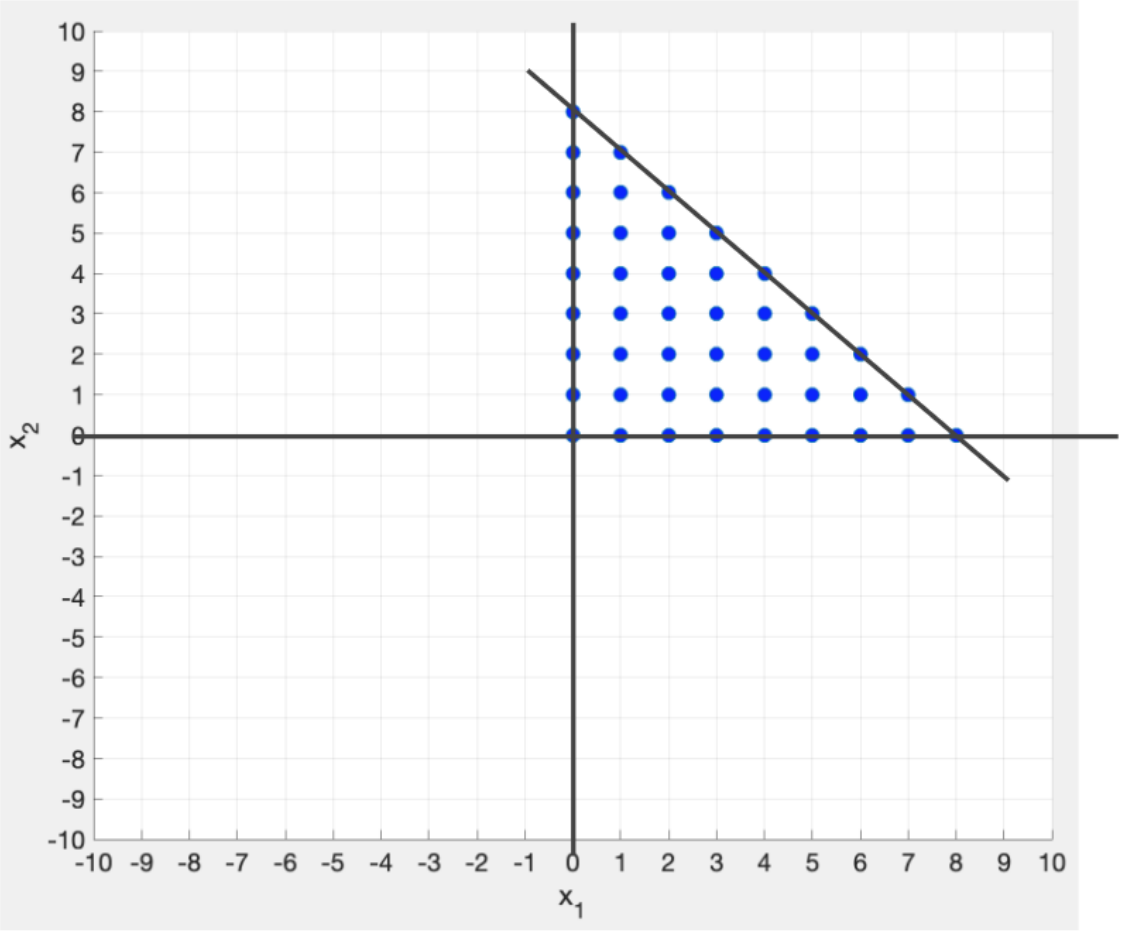

$$\begin{aligned} \max \quad & x_1 + 2x_2 \\ & x_1 + x_2 \leq 8 \\ & x_1 \geq 0 \\ & x_2 \geq 0 \\ & x_1 \in \{0, 1, 2, 3, ...\} \\ & x_2 \in \{0, 1, 2, 3, ...\} \end{aligned}$$

Conjunto factible: todos los puntos azules

Figure: Problema de programación entera: las variables de decisión son enteras.

Optimización: Programación Entera en grafos ejemplo Shortest Path

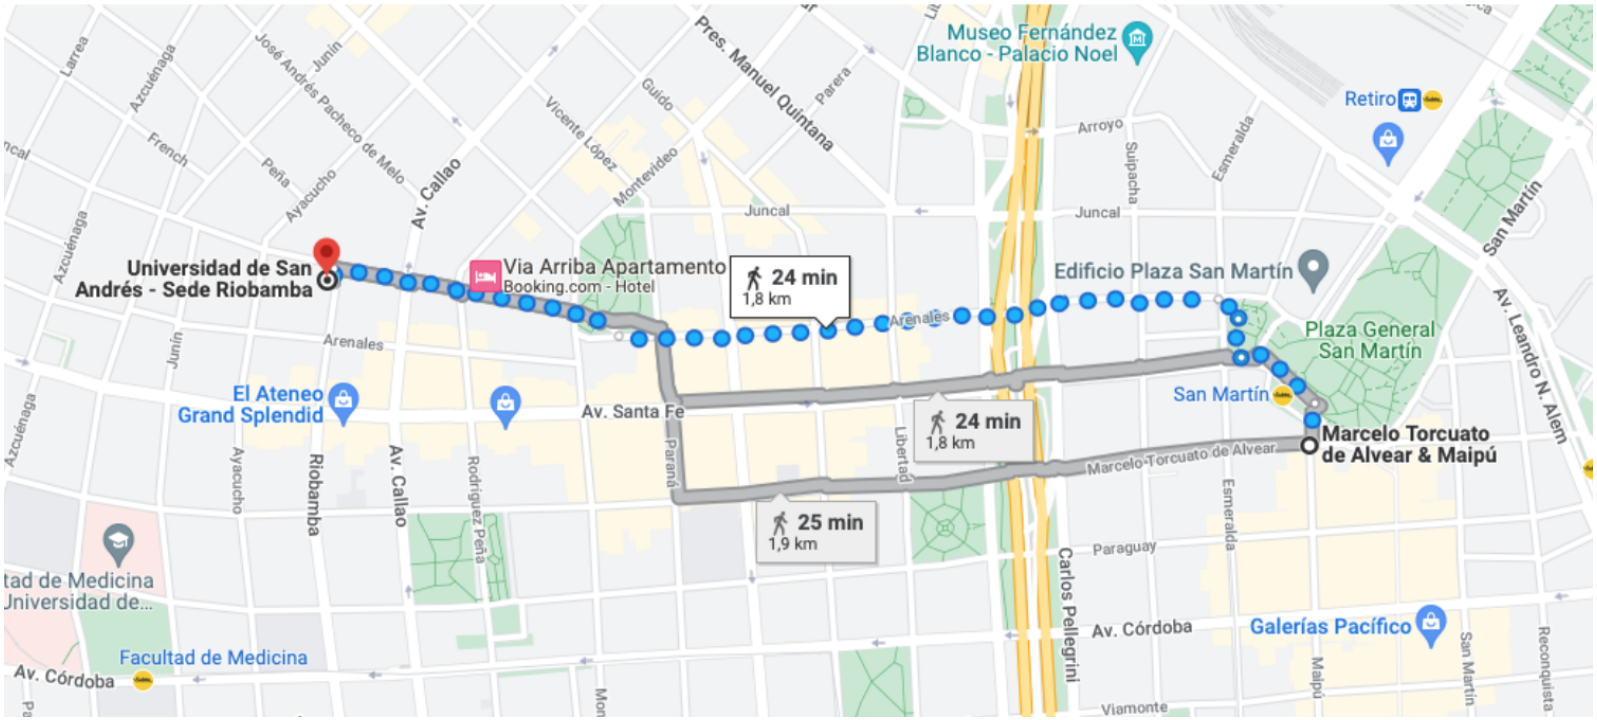

Figure: Programación entera binaria: Camino mas corto entre un nodo inicio y un nodo final

Optimización: Programación Entera en grafos ejemplo Shortest Path

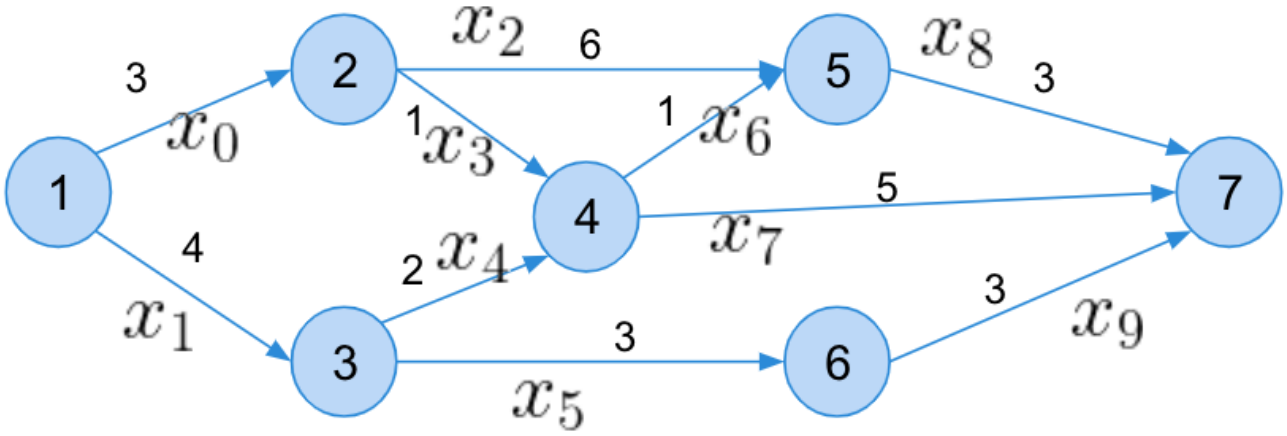

Figure: Programación entera binaria: encontrar el camino mas corto entre un nodo inicio y un nodo final

Optimización: Programación Entera en grafos

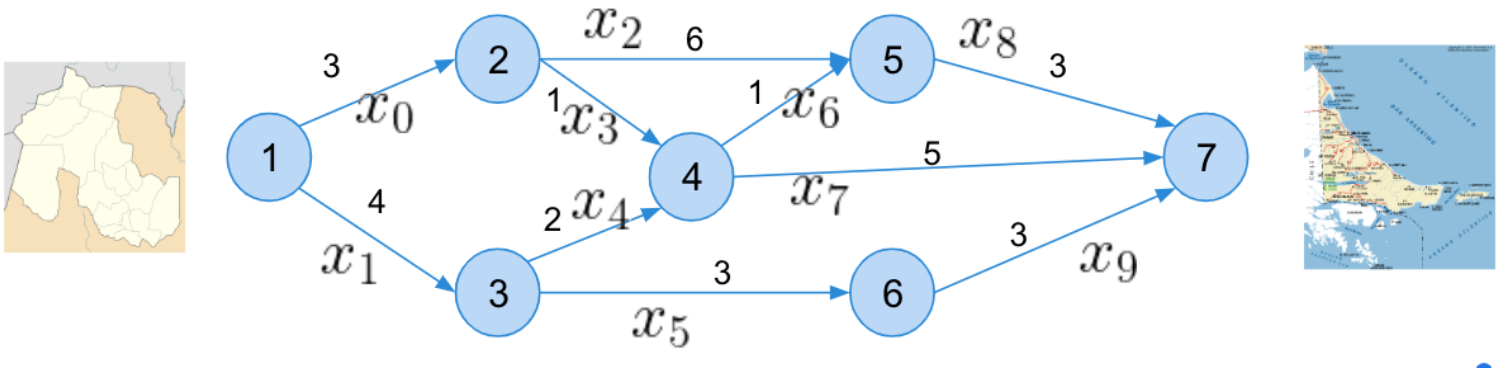

Figure: Programación entera binaria: Camino mas corto entre un nodo inicio y un nodo final

Las variables de decisión x_{ij} son los arcos entre un nodo i y j pesados con un parámetro d_{ij} (ej distancia). La función objetivo $f(x)$ es el mínimo costo de transportar una unidad de flujo desde el nodo origen al nodo destino.
En este ejemplo $x \in \mathbb{R}^9$ con $x_i \in \{0, 1\}$

$$\min_x f(x) = \sum d_{ij} x_{ij}$$

Optimización: Programación Entera en grafos

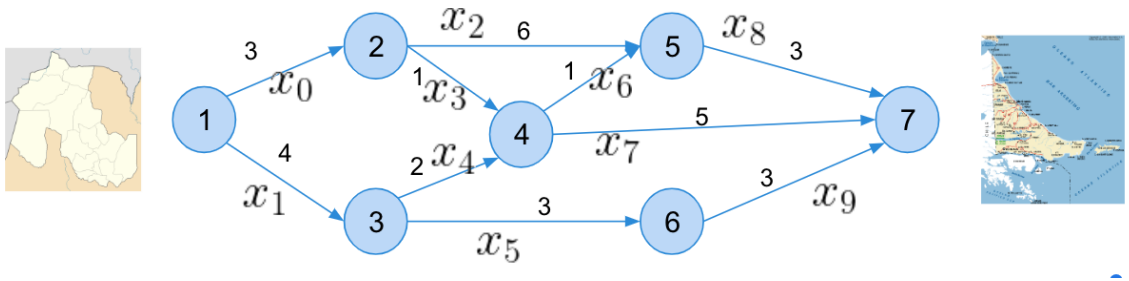

Figure: Camino mas corto entre un nodo inicio y un nodo final

En este ejemplo $x \in \mathbb{R}^9$ con $x_i \in \{0, 1\}$

$$\min_x f(x) = \sum d_{ij} x_{ij}$$

sujeto a las restricciones de que el flujo entrante en cada nodo sea igual al flujo saliente

$$\sum_{k \in N} x_{kj} - \sum_{i \in N} x_{ji} = b_j = 0$$

suponiendo que del nodo origen emite una unidad de flujo y el nodo destino recibe una unidad de flujo (balance entre flujo entrante y saliente)

Funciones convexas

Optimización convexa: conjunto convexo

Un conjunto convexo $\mathcal{C}$ queda definido por aquel que cualquier segmento lineal entre los puntos $x_i, x_j \in \mathcal{C}$

$$\mathbf{x} = t\mathbf{x}_i + (1-t)\mathbf{x}_j \in \mathcal{C}$$

para todo $0 \leq t \leq 1$ también pertenece a $\mathcal{C}$

Optimización convexa: conjunto convexo

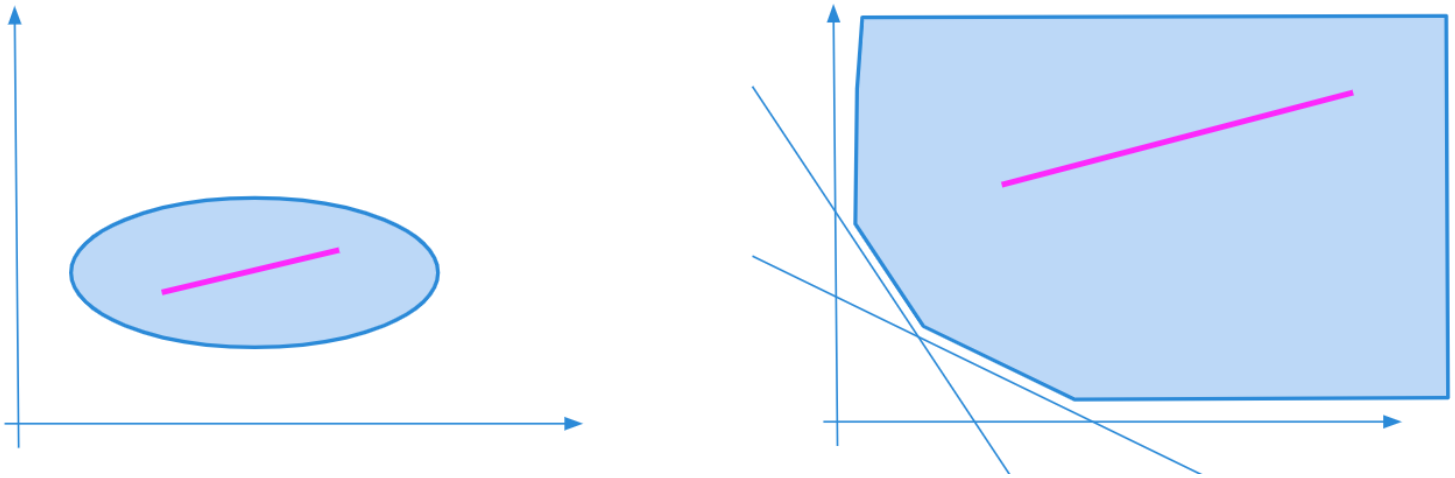

Figure: Ejemplos de conjuntos convexos

Optimización convexa: conjunto convexo

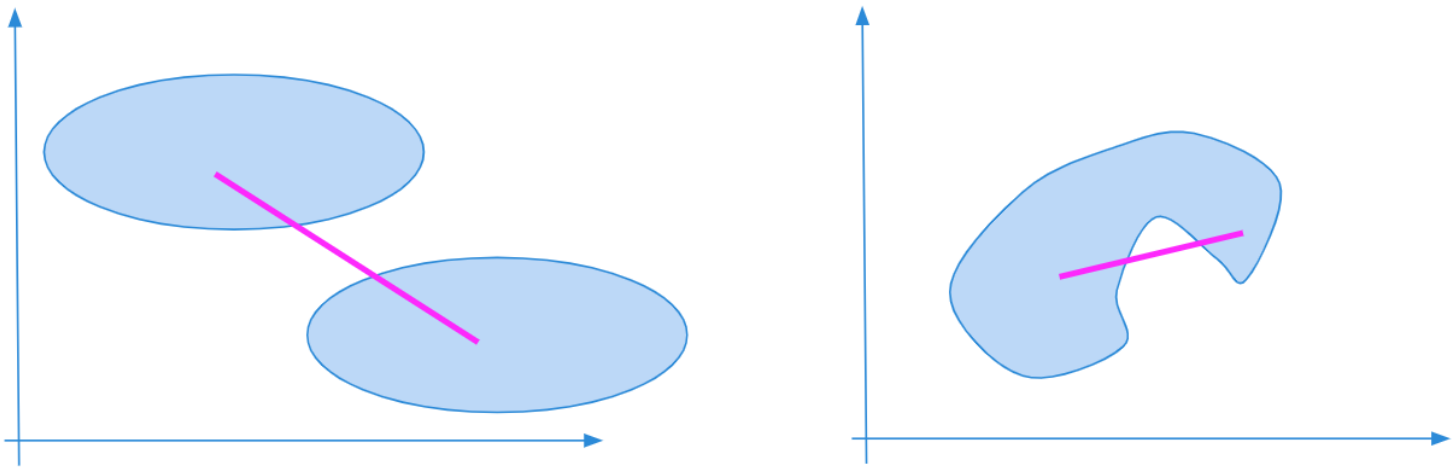

Figure: Ejemplos de conjuntos no convexos

Optimización convexa: conjunto convexo

Conjuntos convexos

- igualdad lineal $Ax = b$
- Desigualdad lineal $Ax \geq b$
- Desigualdad circular $\|x - x_c\|^2 \leq r^2$
- Desigualdad elíptica $\|A(x - x_c)\|^2 \leq 1$
- Desigualdad parabólica $x_1^2 \leq x_2$

Optimización convexa: función convexa

Función convexa

Una función $f : \mathcal{C} \to \mathbb{R}$ con $\mathcal{C} \in \mathbb{R}^n$ es convexa si $\mathcal{C}$ es un conjunto convexo y se cumple

$$f(\lambda \mathbf{x_i} + (1-\lambda)\mathbf{x_j}) \leq \lambda f(\mathbf{x_i}) + (1-\lambda) f(\mathbf{x_j})$$

para todo $x_i, x_j \in \mathcal{C}$ y $\lambda \in [0,1]$. En términos geométricos el segmento lineal entre $(x_i, f(x_i))$ y $(x_j, f(x_j))$ pasa sobre la función f

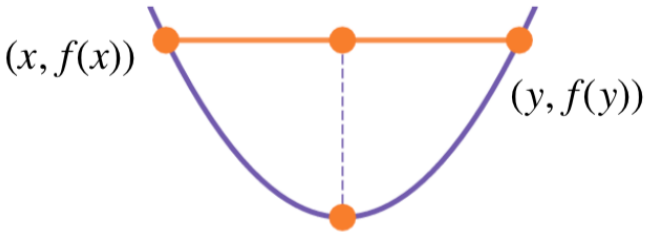

Figure: Función convexa

una función es cóncava si $-f$ es convexa.

Optimización convexa: función convexa

Ejemplos de funciones convexas

- $f(x) = \mathbf{a}^T\mathbf{x} + b$
- $f(x) = e^{ax}$ para cualquier $a \in \mathbb{R}$
- $f(x) = x^\alpha$ para todo $\alpha \geq 1$ o $\alpha \leq 0$
- entropía negativa $f(x) = x\log(x)$
- valor absoluto $f(x) = \|x\|^p$ con $p \geq 1$

Optimización convexa: función convexa

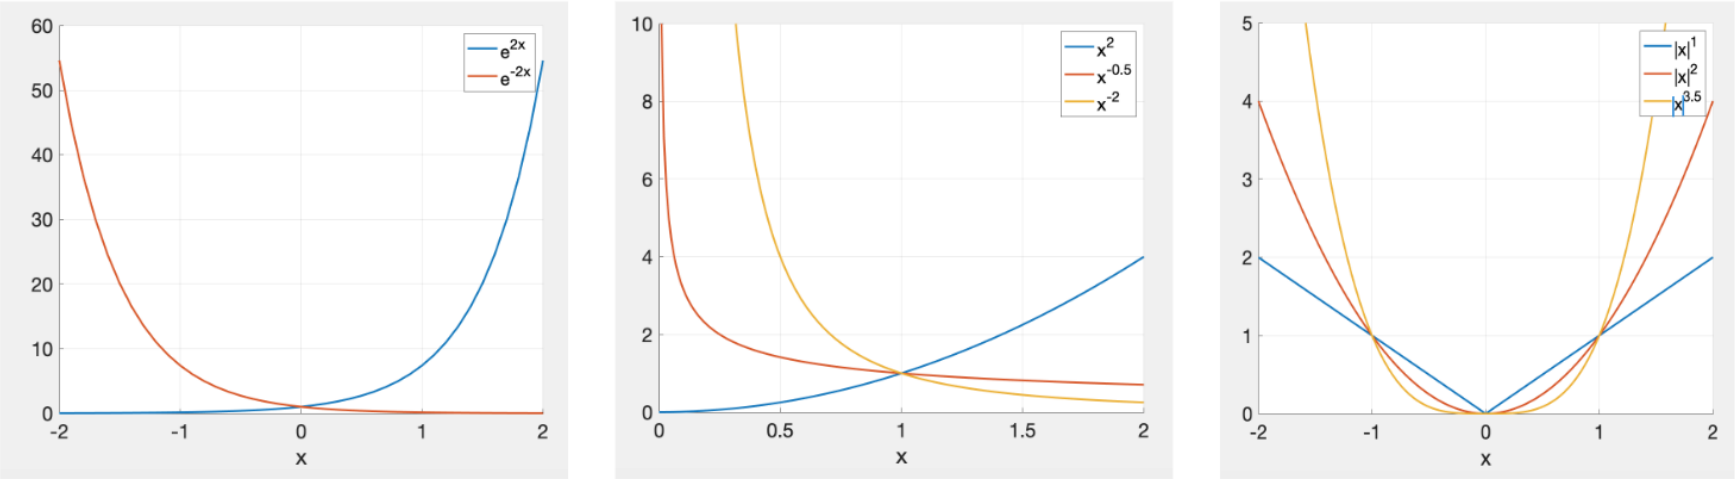

Figure: Función exponencial, potencias, potencias de valor absoluto

Optimización convexa: función convexa

Ejemplos de funciones cóncavas

- $f(x) = \mathbf{a}^T\mathbf{x} + b$
- $f(x) = x^\alpha$ con $x \geq 0$ y $0 \leq \alpha \leq 1$
- $f(x) = \log(x)$ con $x > 0$
- entropía $f(x) = -x\log(x)$ con $x > 0$

Optimización convexa: función cóncava

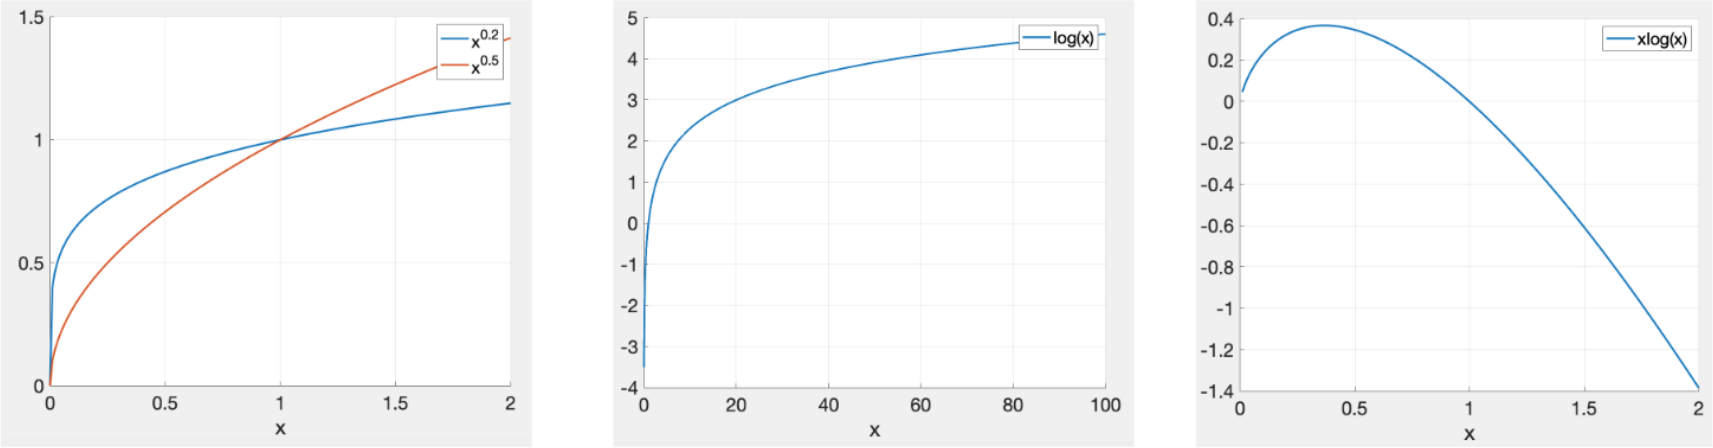

Figure: Potencias, logaritmo, entropía

Optimización convexa: condición de primer orden

Condición de primer orden

Suponer f es diferenciable en el conjunto $\mathcal{C}$

$$\nabla f(\mathbf{x}) := \left(\frac{\partial f}{\partial x_1}(\mathbf{x}), \ldots, \frac{\partial f}{\partial x_d}(\mathbf{x}) \right)^T$$

y el gradiente existe para todo $x \in \mathcal{C}$. Entonces la primer condición:

$$f(\mathbf{x_j}) \geq f(\mathbf{x_i}) + \nabla f(\mathbf{x_i})^\top (\mathbf{x_j} - \mathbf{x_i})$$

donde $x_i, x_j \in \mathcal{C}$. Es decir que la f es el máximo de todas sus tangentes: la aproximación de primer orden de f (derivadas parciales de 1er orden) es un sub-estimador global.

Optimización convexa: condición de primer orden

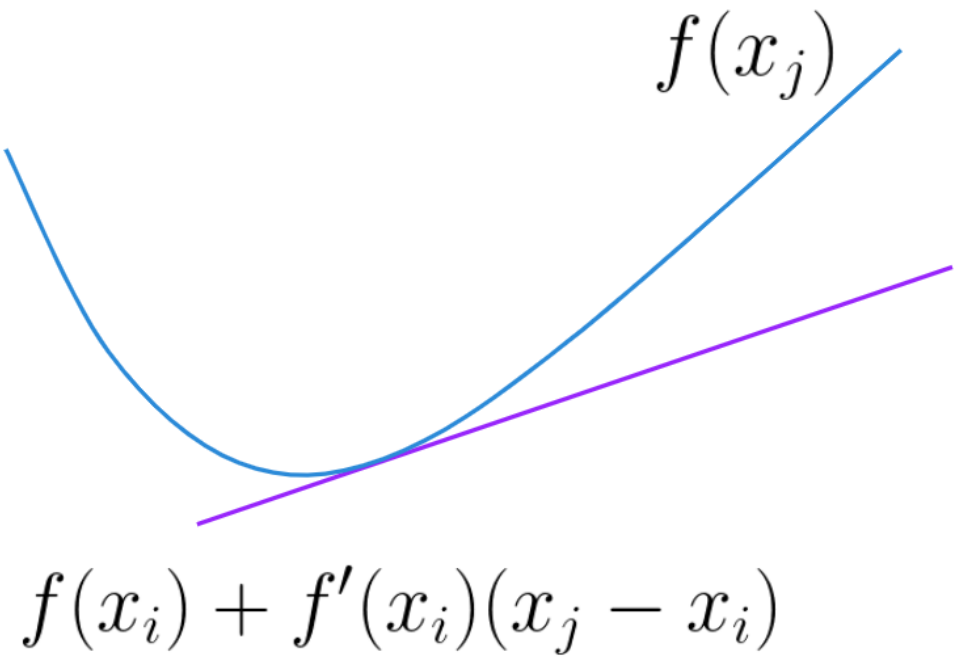

Figure: Condición de 1er orden: la f es el máximo de todas sus tangentes.

Optimización convexa: condición de segundo orden

Condición de 2do orden

si f es doblemente diferenciable en $\mathcal{C}$ el *Hessiano* $\nabla^2 f(\mathbf{x})$ queda definido como

$$\nabla^2 f(\mathbf{x})_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x})$$

por ejemplo

$$H = \begin{pmatrix} f''_{x_1 x_1} & f''_{x_1 x_2} \\ f''_{x_2 x_1} & f''_{x_2 x_2} \end{pmatrix}$$

La condición de 2do orden: para f doblemente diferenciable sobre un dominio convexo *mathcalC* entonces f es convexa si y solo si

$$\nabla^2 f(\mathbf{x}) \geqslant 0$$

es equivalente a decir que el Hessiano sea positivo-semidefinido (todos sus autovalores son no-negativos).

Optimización convexa: condición de segundo orden

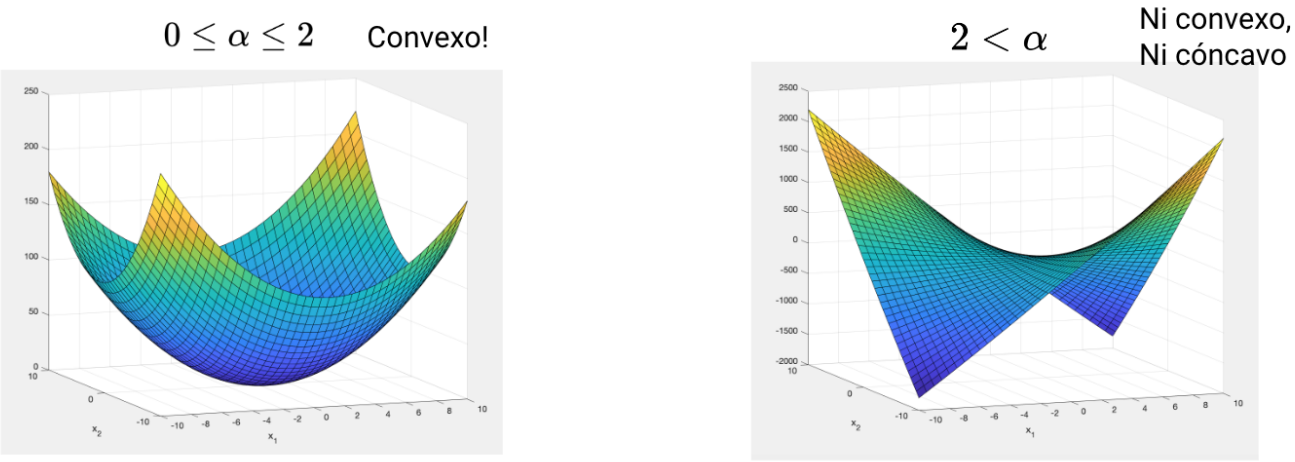

Figure: Función cuadrática con distintos Hessianos

Supongamos la función

$$f(x) = x_1^2 + x_2^2 + \alpha x_1 x_2 = x^T \begin{bmatrix} 1 & \sqrt{\alpha} \\ \sqrt{\alpha} & 1 \end{bmatrix} x$$

Optimización convexa: buscando el óptimo

Optimización en funciones convexas

si

$$\min_x f(x)$$

$$\text{sujeto a } x \in \mathcal{C}$$

si $f(x)$ es convexa y $\mathcal{C}$ es un conjunto convexo entonces **todo mínimo local es un mínimo global** [1].

Optimización convexa

Optimización convexa: buscando el óptimo

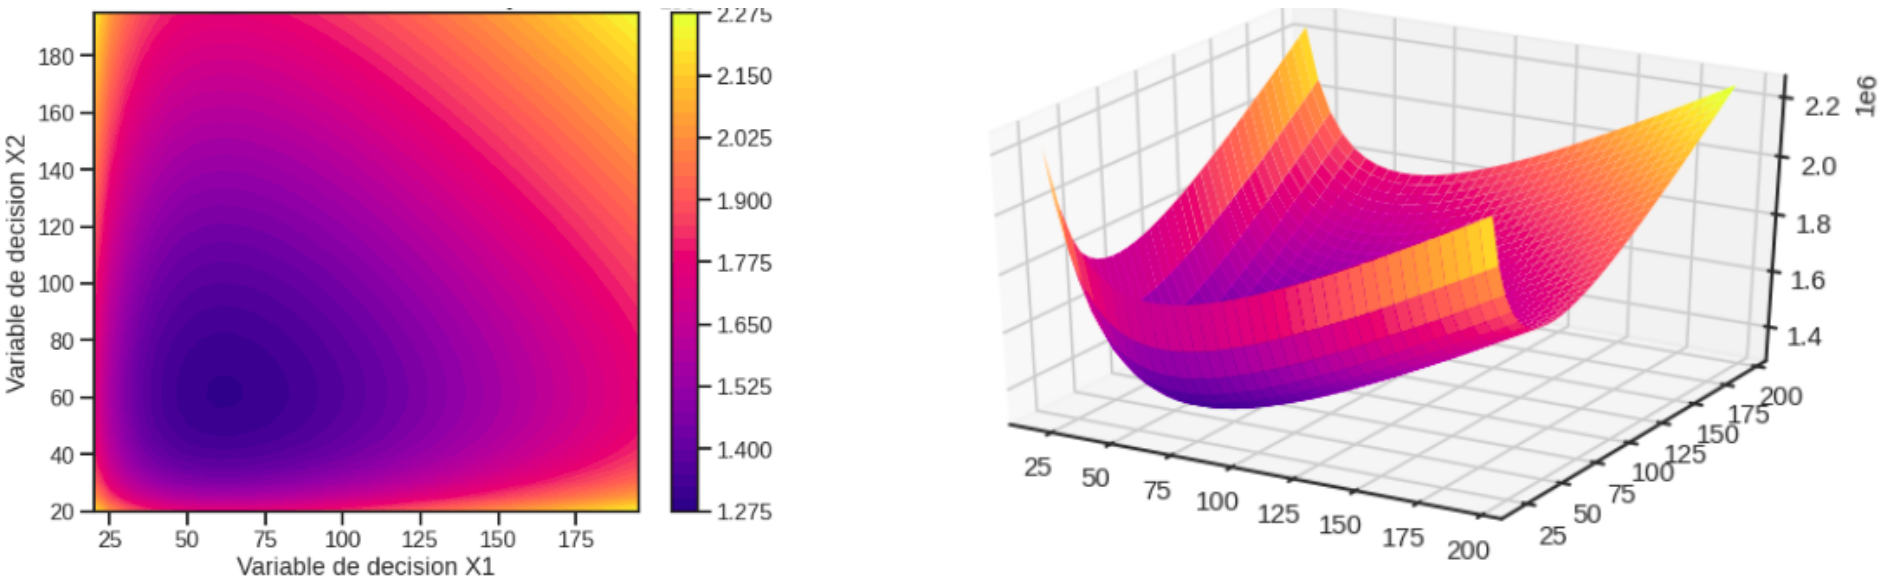

Figure: Función convexa de dos variables

$$f(x_1, x_2) = a_1 + \frac{a_2}{x_1} + a_3 x_1 + \frac{a_4}{x_2} + a_5 x_2$$

Optimización convexa: buscando el óptimo

Optimización en funciones convexas

si

$$\min_x f(x)$$

$$\text{sujeto a } x \in \mathcal{C}$$

si $f(x)$ es convexa y $\mathcal{C}$ es un conjunto convexo entonces **todo mínimo local es un mínimo global** [1].

Optimización convexa: buscando el óptimo

Pregunta

Por que preferiríamos que un problema de optimización sea convexo?

Respuesta

Todos los algoritmos de búsqueda de óptimos como Gradiente descendiente, Gradiente descendiente estocástico, Método de Newton y mas van a **converger al óptimo global**.

Optimización convexa: buscando el óptimo

Convergencia en optimización convexa

En un problema de optimización convexo (por ejemplo, con una función cuadrática) la convergencia al óptimo x^* mediante una serie de soluciones x_t es proporcional a $\frac{1}{t}$

$$f(x_t) - f(x^*) \leq \frac{c}{t}$$

con $t \to \infty$. Esto quiere decir que en un problema convexo la convergencia y el error de aproximación tiende a 0.

Optimización convexa: buscando el óptimo

Mínimo local

Un mínimo local de la función $f(x)$ es aquel $\mathbf{x}^*$ que dado un $\epsilon > 0$ se cumple

$$f(x^*) \leq f(x_i)$$

donde $x_i \in \mathcal{C}$ y se satisface que

$$\|x^* - x_i\| < \epsilon$$

Optimización convexa: buscando el óptimo

Teorema mínimo de una función convexa

Sea $\mathbf{x}^*$ un mínimo local de una función convexa $f(x)$ entonces $\mathbf{x}^*$ es un mínimo global asegurando que

$$f(x^*) \leq f(x_i)$$

para todo $x_i \in \mathcal{C}$

Optimización convexa: buscando el óptimo

Criterio de optimalidad para f diferenciable

Sea $f(x)$ una función convexa y su dominio $x \in \mathcal{C}$ un conjunto convexo entonces un punto x^* minimiza f si se cumple

$$f(x^*) \leq f(x_i)$$

para todo $x_i \in \mathcal{C}$ y además es óptimo si

$$\nabla f(x^*)(x - x^*) \geq 0$$

es decir que todas las direcciones posibles desde x^* estan alineadas con el gradiente $\nabla f(x^*)$

Optimización convexa: buscando el óptimo

Puntos críticos

Si $f(x)$ es convexa y diferenciable en el dominio $x \in \mathcal{C}$ entonces si el punto critico

$$\nabla f(x) = 0$$

es un mínimo global. Recordar la condición de primer orden

$$f(\mathbf{x_j}) \geq f(\mathbf{x_i}) + \nabla f(\mathbf{x_i})^\top (\mathbf{x_j} - \mathbf{x_i})$$

donde $x_i, x_j \in \mathcal{C}$. Es decir que la f es el máximo de todas sus tangentes.

Lectura sugerida

Lecturas sugeridas

- Intro a optimización *Numerical Optimization* libro Nocedal Capítulo 1 y 2 [1]
- Intro a Optimización: *Linear Algebra and Learning from Data* de Gilbert Strang capítulo y sección 6 [2]

Nocedal, J., & Wright, S. J. (Eds.). (1999). Numerical optimization. New York, NY: Springer New York.

Strang, G. (2019). Linear algebra and learning from data (Vol. 4). Cambridge: Wellesley-Cambridge Press.