Métodos Numéricos y Optimización
Lecture 20: Optimización convexa con restricciones

Martín Palazzo

Universidad de San Andrés
Ingeniería en Inteligencia Artificial

palazzom@udesa.edu.ar

June 5, 2024

Overview

1. Optimización Convexa: caso con restricciones
2. Programación lineal: caso con restricciones de desigualdad
3. Optimización cuadrática: caso Cuadrados Mínimos

Optimización Convexa: caso con restricciones

Optimización convexa: caso con restricciones

Supongamos el problema de optimización

$$\min_{x} f(x)$$

sujeto a restricciones de igualdad

$$c_i(x) = 0 \in \mathcal{C}, i \in \varepsilon$$

y/o restricciones de desigualdad

$$c_i(x) \geq 0 \in \mathcal{C}, i \in \mathcal{I}$$

pudiendo definir el conjunto factible de soluciones a ω como

$$\Omega = \{x | c_i(x) = 0, i \in \varepsilon, \ \cap \ x | c_i \geq 0, i \in \mathcal{I}\}$$

Optimización convexa: caso con restricciones

Optimizacion con restricciones

$$\min_{x \in \Omega} f(x)$$

donde Ω es el conjunto factible

Optimización convexa: caso con restricciones

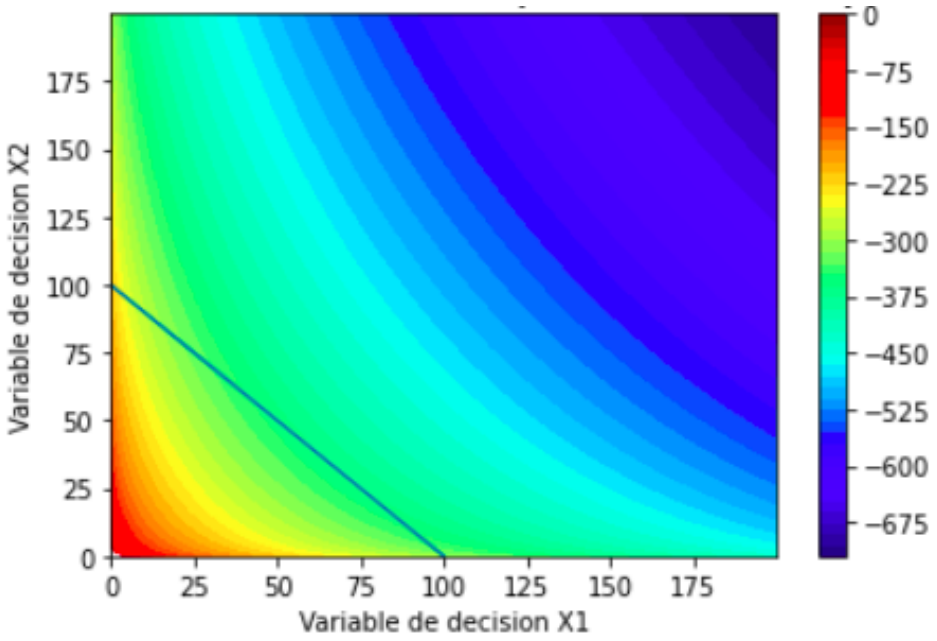

Figure: Función objetivo cuadrática sujeta a una restricción lineal

$$f(x) = -30x_1^{(1/2)} - 20x_2^{(1/2)}$$

sujeto a

$$c_1(x) = x_1 + x_2 \leq 100$$

Optimización convexa: Multiplicadores de Lagrange

Multiplicadores de Lagrange

Una forma de representar el problema de optimización con restricciones es aplicando los multiplicadores de lagrange de manera de obtener la siguiente función a optimizar

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i \in \Omega} \lambda_i c_i(x)$$

para todo $\lambda \geq 0$. Es decir que en este nuevo problema debo encontrar x^* y λ_i para cada restricción.

Optimización convexa: Multiplicadores de Lagrange

en esta nueva función

$$\mathcal{L}(x, \lambda) = f(x) - \sum_{i \in \Omega} \lambda_i c_i(x)$$

cuando $\lambda_i = 0$ estamos en un caso donde la restricción $c_i(x)$ no tiene efecto. A medida que λ aumenta entonces se penaliza mas el espacio de búsqueda dándole mas importancia a dicha restricción.

Optimización convexa: Multiplicadores de Lagrange

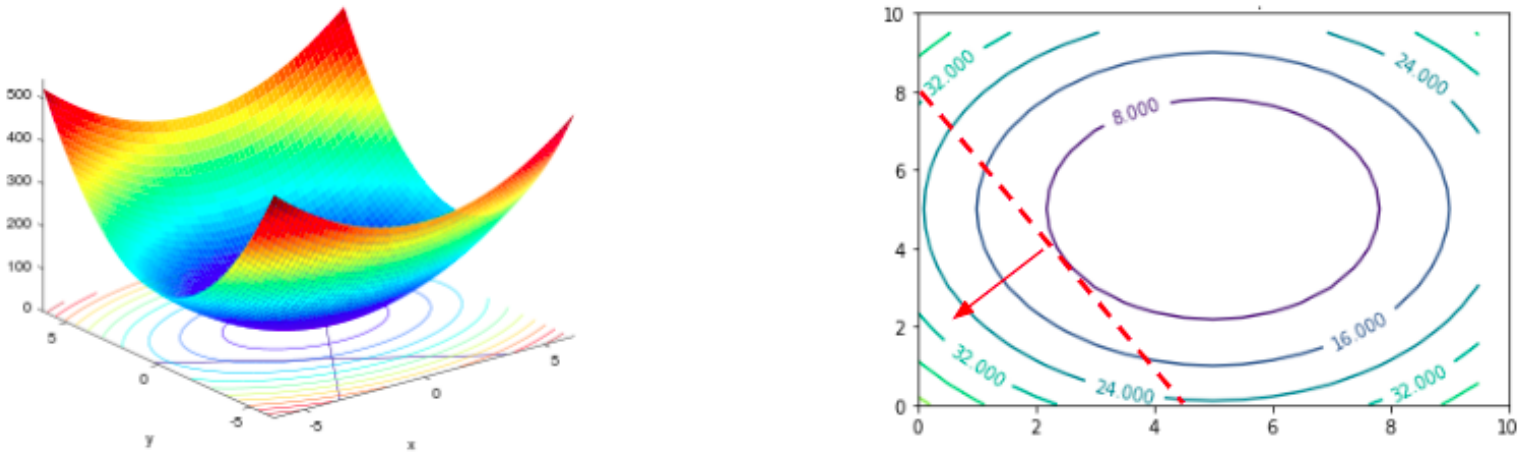

Figure: El efecto de los multiplicadores de lagrange sobre las restricciones

Optimización convexa: Multiplicadores de Lagrange

supongamos entonces la siguiente funcion convexa a optimizar

$$f(x_1, x_2) = a_1 + \frac{a_2}{x_1} + a_3 x_1 + \frac{a_2}{x_2} + a_3 x_2$$

sujeta a las restricciones

$$c_i(x) = b_1 x_1 + b_2 x_2 \leq S$$

el problema se puede reescribir con multiplicadores de Lagrange como la siguiente función

$$L(x_1, x_2, \lambda_i = f(x_1, x_2) + \lambda_i[(b_1 x_1 + b_2 x_2) - S]$$

Optimización convexa: Multiplicadores de Lagrange

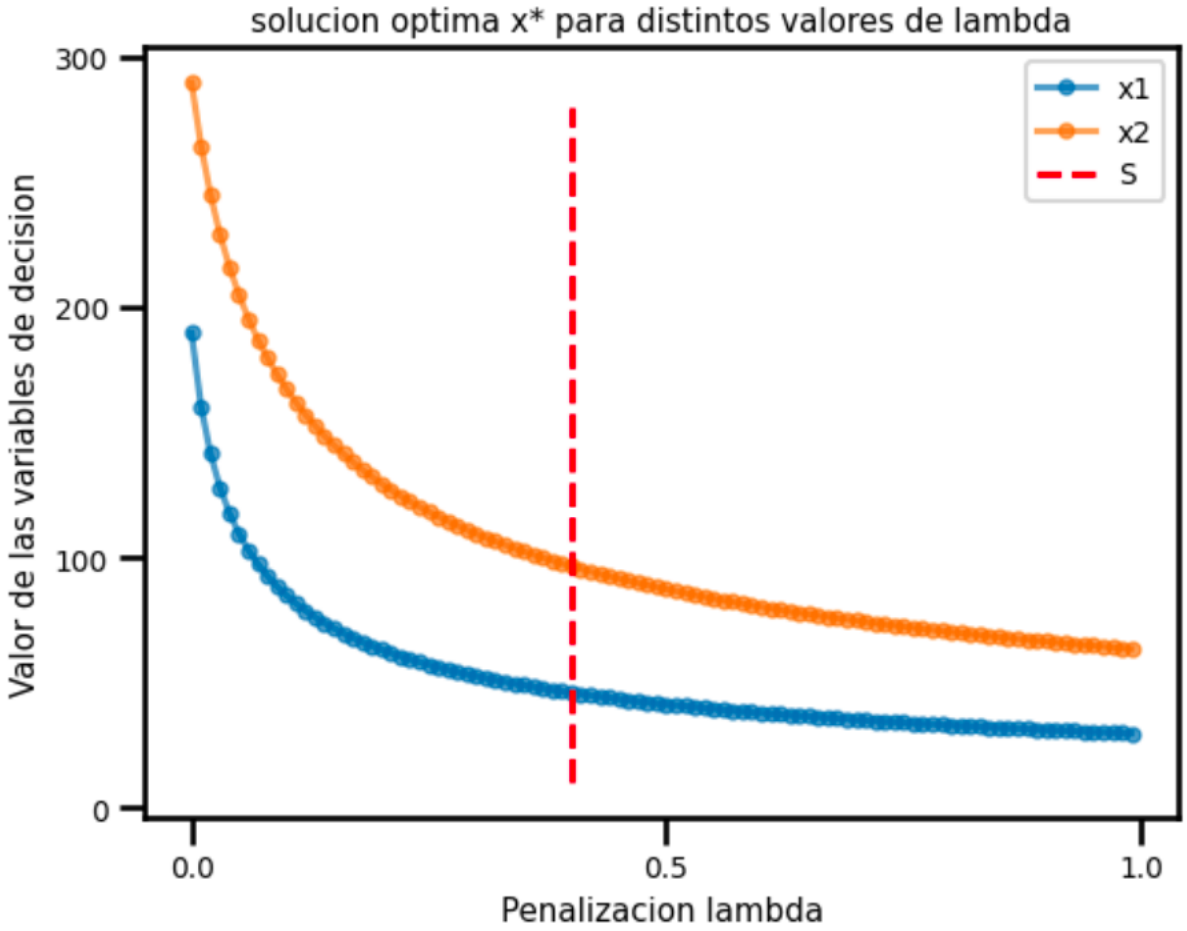

Figure: El efecto de los multiplicadores de lagrange sobre las restricciones

Optimización convexa: Multiplicadores de Lagrange

El punto óptimo con la formulación de Lagrange es x^* con λ^* donde buscamos que se cumpla

$$\nabla \mathcal{L}(x^*, \lambda_i^*) = 0$$

es decir que los gradientes

$$\nabla f(x^*) = \lambda_i \nabla \lambda c_i(x^*)$$

vamos a querer que $\mathcal{L}$ sea lo mas grande posible para λ mientras que simultáneamente $\mathcal{L}$ sea lo mas chica posible para x, es decir es un *saddle point*!! Una forma de solucionarlo es primero hacer una búsqueda por λ y luego una búsqueda por x (existen otros métodos para esto).

Optimización convexa: condiciones KKT

Condiciones Karush-Kuhn-Tucker

Las condiciones de primer orden necesarias para un problema de optimización con restricciones

- $\nabla \mathcal{L}(x^*, \lambda_i^*) = 0$
- $c_i(x^*) \geq 0$ satisface las restricciones de desigualdad
- $c_i(x^*) = 0$ satisface las restricciones de igualdad
- $\lambda_i^* \geq 0$

relacionando los gradientes de la función objetivo y las restricciones

Optimización convexa: condiciones KKT

Restricciones activas vs inactivas

- Una restricción activa $c_i(x)$ sera aquella que ante una leve perturbación hace que la solución x^* se vea afectada. El multiplicador de lagrange $\lambda_i^* > 0$
- Una restricción inactiva $c_j(x)$ sera aquella que ante una leve perturbación la solución x^* no se modifica. El multiplicador de lagrange $\lambda_j^* = 0$.

Programación lineal: caso con restricciones de desigualdad

Optimización: Programación Lineal

Programación lineal: ejercicio

Una empresa desea maximizar las ganancias de sus ventas vendiendo dos productos. La ganancia neta de cada unidad de producto 1 es \$15 y la del producto 2 es \$20. Se disponen de \$80.000 para cubrir costos de producción donde cada unidad de producto 1 cuesta \$200 y cada unidad de producto 2 \$400. No es posible producir mas de 300 unidades en total. Cuantas unidades de cada producto se deben producir para maximizar la ganancia?

Optimización: Programación Lineal

Primero definimos las variables de decision

$$x_1, x_2 \in \mathbb{R}^n$$

la funcion objetivo

$$\max_{x_1,x_2} f(x) = 15x_1 + 20x_2$$

sujeto a (s.t.) las restricciones

$$\begin{aligned} 200x_1 + 400x_2 &\leq 80000 \\ x_1 + x_2 &\leq 300 \\ x_1 &\geq 0 \\ x_2 &\geq 0 \end{aligned}$$

Optimización: Programación Lineal

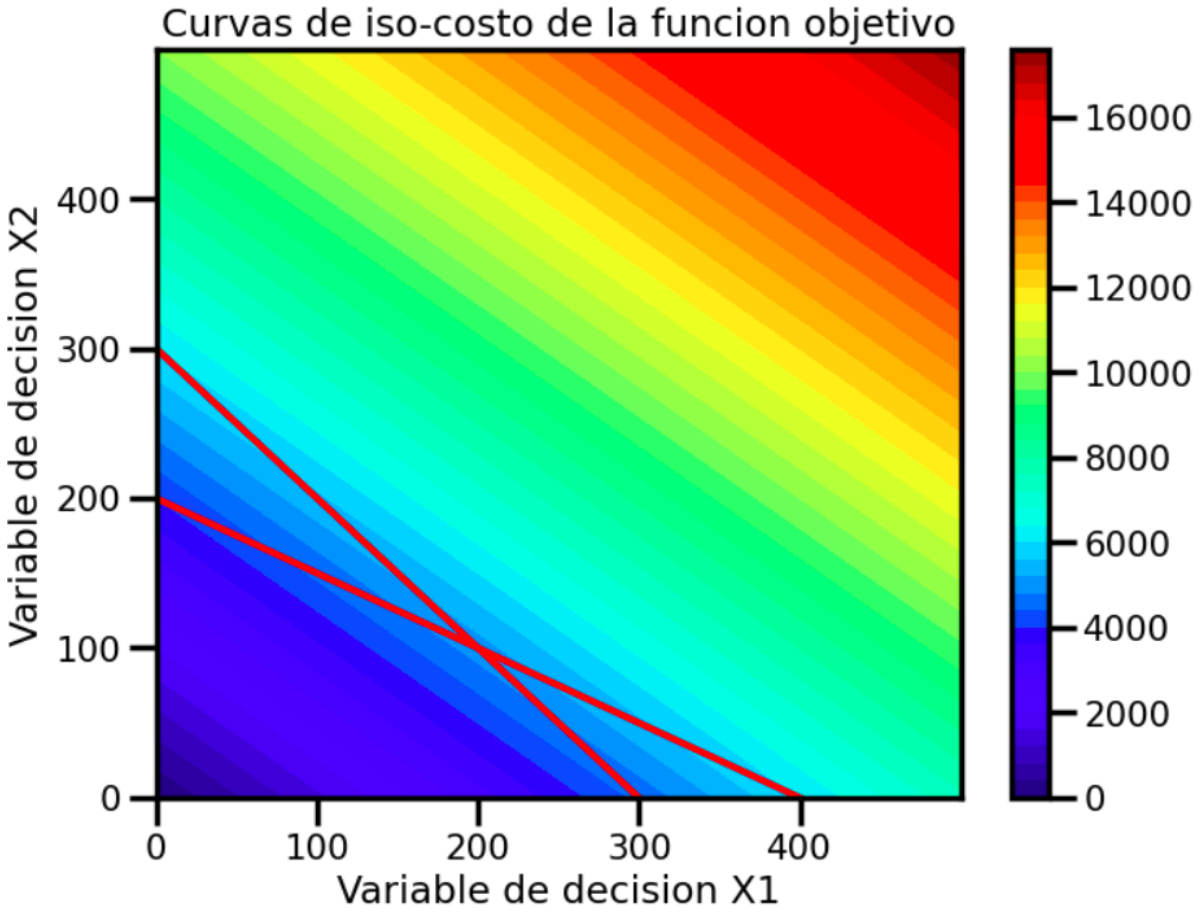

Figure: Problema de programación lineal: maximizacion con restricciones

Optimización: Programación Lineal

Solver de programacion lineal: algoritmo del SIMPLEX

Cuando la función objetivo y las restricciones ambas son lineales, en un contexto de variables de decisión continuas entonces la solución siempre estará sobre uno de los vértices del polígono de soluciones posibles. El algoritmo del SIMPLEX iterativamente buscara soluciones en los vértices con el fin de optimizar la función objetivo en cada paso.

Optimización: Programación Lineal con KKT conditions

Si pensamos el problema como uno de optimización convexa entonces conviene minimizar. Podemos reescribir el problema de maximizaron en uno de minimización. La función objetivo

$$\max_{x_1,x_2} f(x) = -15x_1 - 20x_2$$

sujeto a (s.t.) las restricciones

$$\begin{aligned} c_1(x_1, x_2) = -200x_1 - 400x_2 &\geq -80000 \\ c_2(x_1, x_2) = -x_1 - x_2 &\geq -300 \\ x_1 &\geq 0 \\ x_2 &\geq 0 \end{aligned}$$

Optimización convexa: Multiplicadores de Lagrange

El punto óptimo con la formulación de Lagrange es x^* con λ^* donde buscamos que se cumpla

$$\nabla \mathcal{L}(x^*, \lambda_i^*) = 0$$

es decir que los gradientes

$$\nabla f(x^*) = \lambda_i \nabla \lambda c_i(x^*)$$

vamos a querer que $\mathcal{L}$ sea lo mas grande posible para λ mientras que simultáneamente $\mathcal{L}$ sea lo mas chica posible para x, es decir es un *saddle point*!! Una forma de solucionarlo es primero hacer una búsqueda por λ y luego una búsqueda por x (existen otros métodos para esto).

Optimización convexa: Multiplicadores de Lagrange

Se puede reescribir con multiplicadores de Lagrange como la siguiente función

$$L(x_1, x_2, \lambda_i = f(x_1, x_2) - \lambda_1(a_{11}x_1 + a_{12}x_2) - \lambda_2(a_{21}x_1 + a_{22}x_2)$$

es decir

$$L(x_1, x_2, \lambda_i = -15x_1 - 20x_2 - \lambda_1(-200x_1 - 400x_2 + 80000) + \lambda_2(-x_1 - x_2 + 300) + \lambda_3(x_1, x_2)$$

matricialmente

$$L = c^t x - \lambda_{1,2}^t(Ax - b) - \lambda_3^t x$$

tenemos que encontrar λ_i y x_1, x_2 en el óptimo.

Optimización convexa: condiciones KKT

Condiciones Karush-Kuhn-Tucker

Las condiciones de primer orden necesarias para un problema de optimización con restricciones

- $\nabla \mathcal{L}(x^*, \lambda_i^*) = 0$
- $c_i(x^*) \geq 0$ satisface las restricciones de desigualdad
- $c_i(x^*) = 0$ satisface las restricciones de igualdad
- $\lambda_i^* \geq 0$
- $\lambda_i^* c_i(x^*) = 0$ condición de complementariedad

relacionando los gradientes de la función objetivo y las restricciones

Optimización cuadrática: caso Cuadrados Mínimos

Caso Cuadrados Mínimos

$$\min_{w} \; L(y, \hat{y}) = \min_{w} \; L(y, \hat{f}(x))$$

siendo $\hat{f}(x)$ la función lineal

$$f(x) = w^t x = y$$

donde los parámetros $w \in \mathbb{R}^n$ son las incógnitas. Es decir, hay tantos parámetros como dimensionalidad tenga el problema.

Caso Cuadrados Mínimos

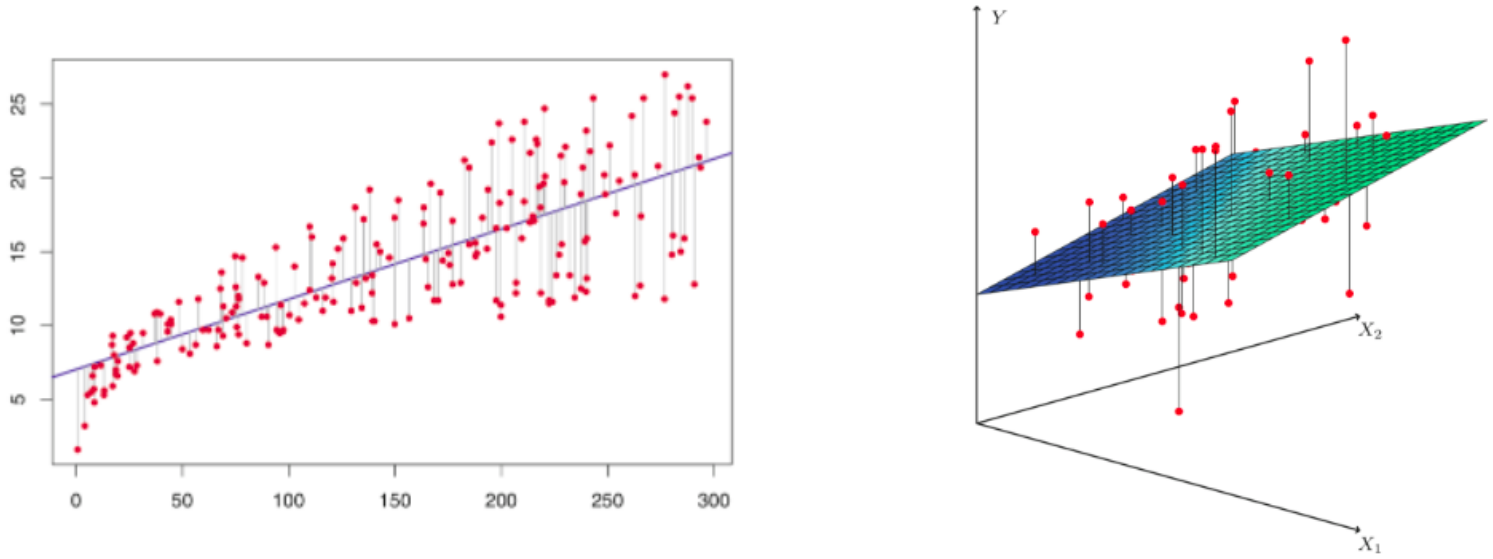

Figure: Regresión lineal: Cuadrados mínimos ordinarios

$$f(x) = w^t x = y$$

Caso Cuadrados Mínimos

La suma de los residuos al cuadrado (RSS = Residual squared sums) es la función objetivo y se escribe

$$\mathrm{RSS}(w) = L(w) = \sum_i^n (y_i - f(x_i))^2$$

$$\mathrm{RSS}(w) = L(w) = \sum_i^n \left(y_i - w_0 - \sum_j^d x_{ij} w_j\right)^2$$

que es equivalente a minimizar la norma

$$\min_w \|Xw - y\|^2$$

Caso Cuadrados Mínimos

El mínimo de esta función

$$\min_{w} \|Xw - y\|^2$$

podemos determinarlo analíticamente por ser una función cuadrática

$$\frac{\partial \mathrm{L}}{\partial w} = 0$$

quedando

$$\hat{w} = (\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X}^T\mathbf{y}$$

Caso Cuadrados Mínimos

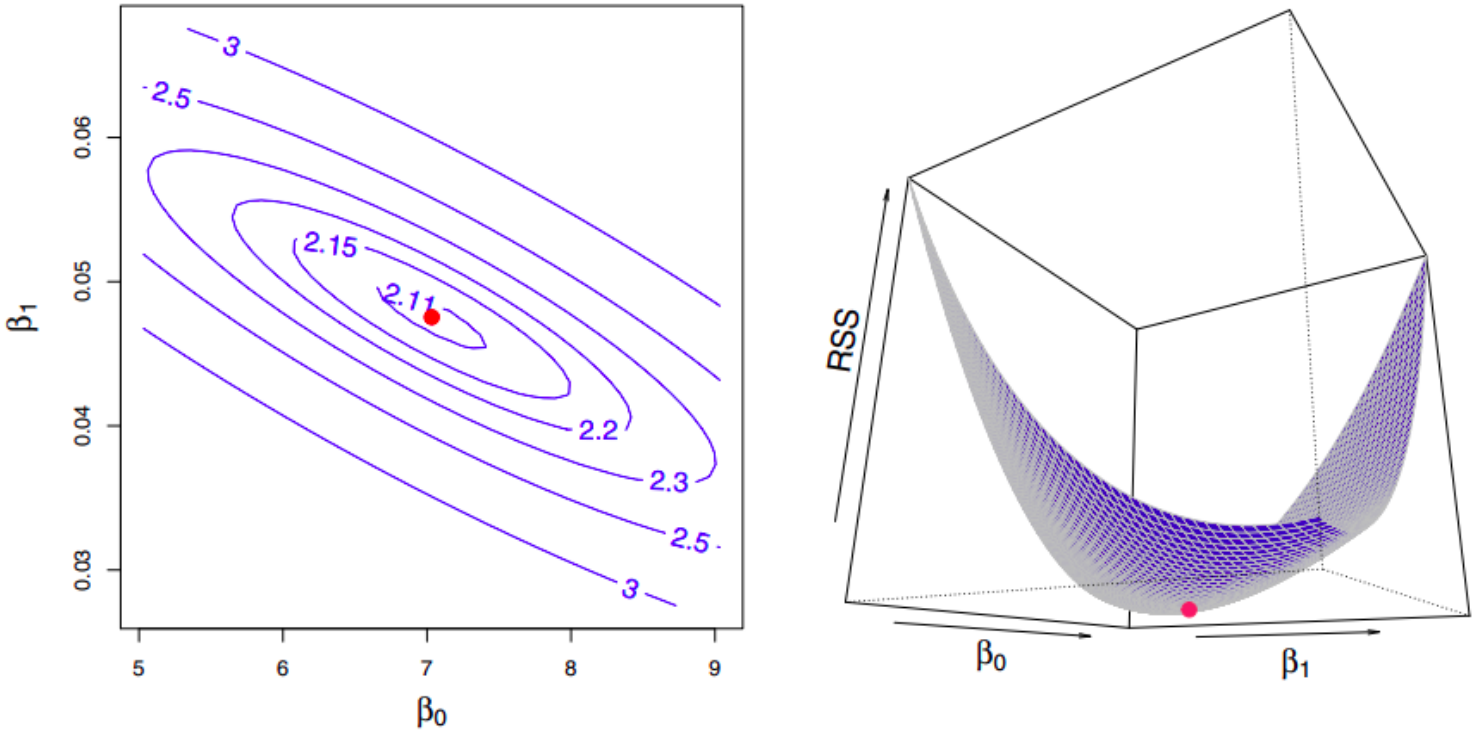

Figure: Regresión lineal: Función objetivo en cuadrados mínimos ordinarios [3]

Caso Cuadrados Mínimos con restricciones (penalización)

En caso de penalizar el vector solución w agregamos un termino (equivalente a la formulación de lagrange!!)

$$\hat{w}^{\text{ridge}} = \underset{w}{\text{argmin}} \left\{ \sum_{i=1}^{N} \left(y_i - w_0 - \sum_{j=1}^{d} x_{ij} w_j \right)^2 + \delta \sum_{j=1}^{d} w_j^2 \right\}$$

se puede reescribir como un problema de optimización con restricciones

$$\hat{w}^{\text{ridge}} = \underset{w}{\text{argmin}} \left\{ \sum_{i=1}^{N} \left(y_i - w_0 - \sum_{j=1}^{d} x_{ij} w_j \right)^2 \right\}$$

sujeto a una cota s que limita las soluciones posibles

$$\sum_{i=1}^{n} w_j^2 < s$$

Caso Cuadrados Mínimos con restricciones (penalización)

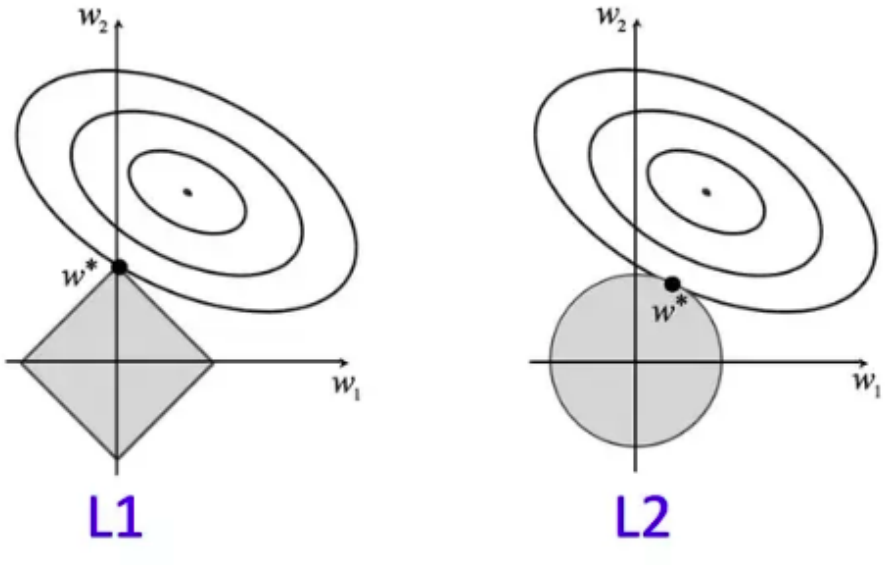

Figure: Regresión lineal: Optimización de cuadrados mínimos ordinarios con restricción a los parámetros incógnita utilizando la norma L_1 y norma L_2 respectivamente [3]

Caso Cuadrados Mínimos

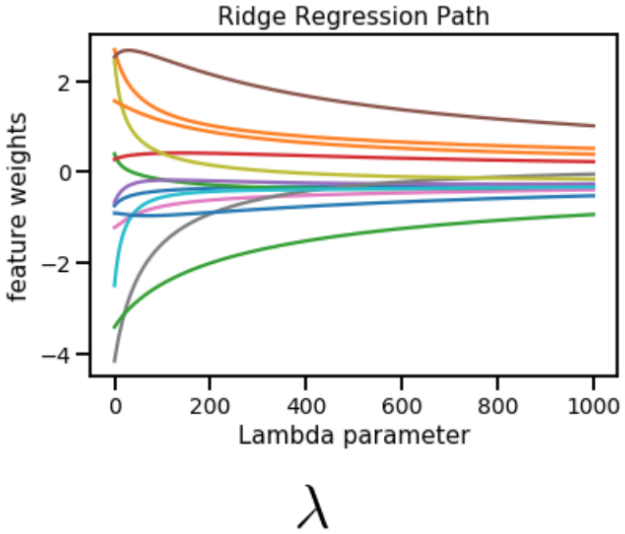

Figure: Vector solución w para distintas penalizaciones

$$\mathbf{min}\ \|X\boldsymbol{w} - \boldsymbol{y}\|^2 + \delta\|\boldsymbol{w}\|^2$$

Matricialmente es equivalente a resolver

$$\left(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X} + \boldsymbol{\delta I}\right)\widehat{\boldsymbol{w}} = X^{\mathrm{T}}\boldsymbol{y}$$

y es equivalente a la formulación de Lagrange!!

Lectura sugerida

Lecturas sugeridas

- Optimización con restricciones *Numerical Optimization* libro Nocedal Capítulo 12 [1]
- Intro a Optimización: *Linear Algebra and Learning from Data* de Gilbert Strang capítulo y sección 6 [2]
- Ridge Regression: *Introduction to Statistical Learning* capitulo 6.2.1 [3]

Nocedal, J., & Wright, S. J. (Eds.). (1999). Numerical optimization. New York, NY: Springer New York.

Strang, G. (2019). Linear algebra and learning from data (Vol. 4). Cambridge: Wellesley-Cambridge Press.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An introduction to statistical learning (Vol. 112, p. 18). New York: springer.